ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC VÀ KỸ THUẬT THÔNG TIN

HỒ NGUYỄN THIÊN VŨ
NGUYỄN PHI LONG

KHÓA LUẬN TỐT NGHIỆP

BỘ DỮ LIỆU THỬ THÁCH KHẢ NĂNG HIỂU ẨN DỤ TIẾNG VIỆT DÀNH CHO CÁC MÔ HÌNH NGÔN NGỮ LỚN (LLMS)

A BENCHMARK DATASET FOR EVALUATING VIETNAMESE METAPHOR UNDERSTANDING IN LLMS

CỬ NHÂN NGÀNH KHOA HỌC DỮ LIỆU

TP. HỒ CHÍ MINH, 2025

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC VÀ KỸ THUẬT THÔNG TIN

HỒ NGUYỄN THIÊN VŨ – 22521689

NGUYỄN PHI LONG – 22520818

KHÓA LUẬN TỐT NGHIỆP

BỘ DỮ LIỆU THỬ THÁCH KHẢ NĂNG HIỂU ẨN DỤ TIẾNG VIỆT DÀNH CHO CÁC MÔ HÌNH NGÔN NGỮ LỚN (LLMS)

A BENCHMARK DATASET FOR EVALUATING VIETNAMESE METAPHOR UNDERSTANDING IN LLMS

CỬ NHÂN NGÀNH KHOA HỌC DỮ LIỆU

GIẢNG VIÊN HƯỚNG DẪN

TS. NGUYỄN VĂN KIỆT

TP. HỒ CHÍ MINH, 2025

THÔNG TIN HỘI ĐỒNG CHẤM KHÓA LUẬN TỐT NGHIỆP

Hội đồng chấm khóa luận tốt nghiệp, thành lập theo Quyết định số …… ngày …….. của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

LỜI CẢM ƠN

Lời đầu tiên, nhóm chúng em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu và quý Thầy Cô Trường Đại học Công nghệ Thông tin, đặc biệt là quý Thầy Cô Khoa Khoa học và Kỹ thuật Thông tin. Quý Thầy Cô đã tận tâm giảng dạy, truyền đạt những kiến thức nền tảng và kỹ năng quý báu, tạo điều kiện thuận lợi nhất cho chúng em trong suốt quá trình học tập, nghiên cứu tại trường.

Đặc biệt, nhóm xin bày tỏ lòng biết ơn sâu sắc đến TS. Nguyễn Văn Kiệt, người đã trực tiếp hướng dẫn và tận tình chỉ bảo chúng em trong suốt thời gian thực hiện khóa luận. Thầy không chỉ định hướng chuyên môn, tháo gỡ những khó khăn trong nghiên cứu mà còn luôn động viên, tiếp thêm sự tự tin để nhóm có thể hoàn thành tốt đề tài này.

Mặc dù đã rất nỗ lực, nhưng do kiến thức và kinh nghiệm thực tế còn hạn chế nên khóa luận khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp, chỉ dẫn của quý Thầy Cô để hoàn thiện hơn, cũng như tích lũy thêm bài học kinh nghiệm làm hành trang vững chắc cho con đường sự nghiệp sau này.

Một lần nữa, chúng em xin chân thành cảm ơn!

Thành phố Hồ Chí Minh, tháng 12 năm 2025

Nhóm tác giả

Hồ Nguyễn Thiên Vũ

Nguyễn Phi Long

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI 3
1.1. Lý do chọn đề tài 3
1.2. Thách thức 4
1.3. Mục tiêu 5
1.4. Đối tượng và phạm vi nghiên cứu 5
CHƯƠNG 2: CÁC CÔNG TRÌNH LIÊN QUAN 6
2.1. Nghiên cứu nền tảng về hiểu ẩn dụ trong NLP 6
2.2. Các bộ dữ liệu ẩn dụ cho tiếng Anh 6
2.3. Các bộ dữ liệu ẩn dụ cho tiếng Tây Ban Nha và nghiên cứu song ngữ 8
2.4. Các bộ dữ liệu ẩn dụ cho tiếng Trung 8
2.5. Các bộ dữ liệu ẩn dụ đa phương thức 9
2.6. Các bộ dữ liệu ẩn dụ cho ngôn ngữ ít tài nguyên 9
2.7. Khoảng trống nghiên cứu và vị trí của ViMUNCH 9
CHƯƠNG 3: XÂY DỰNG BỘ DỮ LIỆU 11
3.1. Định nghĩa các nhiệm vụ 12
3.1.1. Nhận diện ẩn dụ (Metaphor Identification) 12
3.1.2. Diễn giải và phân loại ẩn dụ (Metaphor Interpretation & Classification) 13
3.1.3. Đánh giá câu diễn giải (Paraphrase Judgement) 15
3.2. Thu thập, tiền xử lý dữ liệu 16
3.3. Gán nhãn dữ liệu 18
3.4. Phân tích dữ liệu 35
3.4.1 Mô tả dữ liệu 35
3.4.2 Phân bố dữ liệu. 38
3.4.3 Chia dữ liệu 46
CHƯƠNG 4: THỬ NGHIỆM VÀ KẾT QUẢ 49
4.1 Tổng quát thử nghiệm 49
4.1.1. Các nhiệm vụ đánh giá (multitask) 49
4.1.2. Các mô hình thử nghiệm 50
4.2 Cài đặt thử nghiệm 52
4.2.1 Dữ liệu và phạm vi đánh giá 52
4.2.2 Hướng tiếp cận 52
4.2.3 Quy trình multitask và chuẩn hóa đầu ra 53
4.2.4 Thiết lập suy luận và đảm bảo công bằng 53
4.2.5 Fine-Tuning 54

4.3 Độ đo đánh giá 55
4.3.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification) 55
4.3.2 Task 1B: Trích xuất span ẩn dụ (Span Extraction) 56
4.3.3 Task 2: Phân loại ẩn dụ (Metaphor Classification) 57
4.3.4 Task 3: Diễn giải ẩn dụ (Metaphor Interpretation) 58
4.3.5 Task 4: Chấm điểm diễn giải (Paraphrase Judgement) 60
4.3.6 Tóm tắt phạm vi tính độ đo theo nhiệm vụ 60
4.4 Kết quả thử nghiệm 61
4.4.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification) 61
4.4.2. Task 1B: Trích xuất span ẩn dụ (Span Extraction) 63
4.4.3. Task 2: Phân loại loại ẩn dụ (Metaphor Classification) 64
4.4.4. Task 3: Diễn giải ẩn dụ (Metaphor Interpretation) 65
4.4.5. Task 4: Chấm điểm theo rubric (Paraphrase Judgement) 66
4.5 Phân tích lỗi và thảo luận 67
4.5.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification) 68
4.5.2 Task 1B: Trích xuất span ẩn dụ (Span Extraction) 69
4.5.3 Task 2: Phân loại loại ẩn dụ (Metaphor Classification) 69
4.5.4 Task 3: Diễn giải ẩn dụ (Metaphor Interpretation) 70
4.5.5 Task 4: Chấm điểm theo rubric (Paraphrase Judgement) 71
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 73
5.1. Kết luận 73
5.2. Hạn chế 75
5.3. Hướng phát triển 76
CAM KẾT SỬ DỤNG DỮ LIỆU 77
TÀI LIỆU THAM KHẢO 78

DANH MỤC HÌNH

Hình 3.1: Tổng quan quy trình xây dựng ViMUNCH 12
Hình 3.2: Giao diện trang chủ của công cụ gán nhãn hỗ trợ chú thích 20
ẩn dụ tiếng Việt 20
Hình 3.3: Mức độ đồng thuận giữa các annotator (Inter-annotator Agreement) 36
Hình 3.4: Mức độ nhất quán trong gán nhãn của từng annotator (Intra-annotator Agreement) 37
Hình 3.5: Phân bố các loại ẩn dụ trong bộ dữ liệu ViMUNCH 41
Hình 3.6: Phân bố độ dài câu trong bộ dữ liệu ViMUNCH 42
Hình 3.7: Phân bố số lượng và tỷ lệ các loại ẩn dụ 43
Hình 3.8: Phân bố thể loại Thơ và Văn xuôi 44
Hình 3.9: Thống kê tỉ lệ ẩn dụ theo thể loại (%) 45
Hình 3.10: Top 15 từ/cụm từ ẩn dụ xuất hiện nhiều nhất 46
Hình 3.11: Ma trận tương quan giữa các tiêu chí đánh giá diễn giải 47
Hình 3.12: So sánh tỷ lệ câu chứa ẩn dụ giữa các tập train/dev/test 50
Hình 3.13: So sánh phân bố độ dài câu giữa các tập train/dev/test 50
Hình 3.14: So sánh phân bố các loại ẩn dụ giữa các tập train/dev/test\ 51

DANH MỤC BẢNG

Bảng 3.1: Ví dụ minh họa cho nhiệm vụ nhận diện câu chứa ẩn dụ 13
Bảng 3.2: Hệ thống các loại ẩn dụ được sử dụng trong bộ dữ liệu ViMUNCH 14
Bảng 3.3: Ví dụ minh họa cho nhiệm vụ diễn giải và phân loại ẩn dụ 16
Bảng 3.4: Ví dụ minh họa cho nhiệm vụ đánh giá chất lượng diễn giải ẩn dụ 17
Bảng 3.5: Ví dụ thang điểm độ tương đồng ngữ nghĩa giữa câu gốc và câu diễn giải 29
Bảng 3.6: Nhóm các thuộc tính chính mô tả dữ liệu gán nhãn 38
Bảng 3.7: Nhóm các thuộc tính trích dẫn phục vụ thống kê và kiểm soát chất lượng dữ liệu 39
Bảng 3.8: Các điểm thành phần dùng trong đánh giá diễn giải ẩn dụ 40
Bảng 3.9: Các điểm tổng hợp phản ánh chất lượng diễn giải và mức độ tương đồng ngữ nghĩa 40
Bảng 3.10: Thống kê những đặc điểm bất thường 48
Bảng 4.1: Kết quả thử nghiệm nhiệm vụ nhận diện ẩn dụ 64
Bảng 4.2: Kết quả thử nghiệm nhiệm vụ trích xuất span ẩn dụ 66
Bảng 4.3: Kết quả thử nghiệm nhiệm vụ phân loại loại ẩn dụ 67
Bảng 4.4: Kết quả thử nghiệm nhiệm vụ diễn giải ẩn dụ 68
Bảng 4.5: Kết quả thử nghiệm nhiệm vụ đánh giá diễn giải ẩn dụ 69

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Ý nghĩa
1	ViMUNCH	Vietnamese Metaphor Understanding Challenge — Bộ ngữ liệu ViMUNCH (benchmark hiểu ẩn dụ tiếng Việt)
2	LLMs	Large Language Models – Các mô hình ngôn ngữ lớn
3	VUA	VU Amsterdam Metaphor Corpus – Bộ dữ liệu ẩn dụ do Đại học Amsterdam xây dựng
4	MRWs	Metaphorical Related Words – Các từ/cụm từ có quan hệ ẩn dụ
5	MPEC	Metaphor Processing Evaluation Corpus – Tập dữ liệu đánh giá xử lý ẩn dụ
6	MUNCH	Metaphor Understanding Challenge Dataset for LLMs – Bộ dữ liệu thách thức đánh giá khả năng hiểu ẩn dụ của các mô hình ngôn ngữ lớn
7	HTML	HyperText Markup Language – Ngôn ngữ đánh dấu siêu văn bản
8	JSON	JavaScript Object Notation – Định dạng dữ liệu dạng đối tượng JavaScript
9	NLP	Natural Language Processing – Xử lý ngôn ngữ tự nhiên
10	SEA	Southeast Asia – khu vực Đông Nam Á (dùng khi phân nhóm mô hình)
11	SFT	Supervised Fine-tuning – fine-tuning có giám sát
12	LoRA	Low-Rank Adaptation – phương pháp fine-tuning hiệu quả tài nguyên
13	IoU	Intersection over Union – độ đo chồng lắp span
14	EM	Exact Match – khớp tuyệt đối ranh giới span
15	ROUGE-L	Độ đo dựa trên LCS (chuỗi con chung dài nhất)
16	chrF	F-score dựa trên n-gram ký tự
17	MAE	Mean Absolute Error – độ lệch tuyệt đối trung bình

18	QWK	Quadratic Weighted Kappa – hệ số đồng thuận có trọng số bậc hai
19	TP / FP / FN / TN	True/False Positive/Negative – các thành phần của confusion matrix
20	ZS	Zero-shot – Thiết lập không dùng ví dụ minh họa
21	FS	Few-shot – Thiết lập dùng một số ví dụ minh họa (vd. 5-shot)
22	FT	Fine-tuning – Thiết lập tinh chỉnh mô hình
23	Prec./P	Precision – Độ chính xác theo dự đoán dương
24	Rec./R	Recall – Độ bao phủ dương tính
25	F1	F1-score – Trung bình điều hòa giữa Precision và Recall
26	Acc.	Accuracy – Độ chính xác tổng thể
27	Overlap-F1	Overlap F1 (character-level) – F1 chồng lấn span theo ký tự (Task 1B)
28	FP span rate	False Positive span rate – Tỉ lệ dự đoán span sai trên câu không ẩn dụ
29	Macro-F1	Macro-averaged F1 – F1 trung bình theo nhãn (đa nhãn)
30	Micro-F1	Micro-averaged F1 – F1 gộp toàn bộ nhãn/mẫu (đa nhãn)
31	Subset Acc.	Subset Accuracy – Đúng tuyệt đối tập nhãn (đa nhãn)
32	SimCSE	Sentence Embedding & Cosine Similarity – Embedding câu (SimCSE) và độ tương đồng cosin giữa hai embedding

TÓM TẮT KHÓA LUẬN

Ẩn dụ là một hiện tượng ngôn ngữ phổ biến, phản ánh cơ chế ánh xạ khái niệm giữa miền nguồn và miền mục tiêu, đóng vai trò quan trọng trong tư duy và giao tiếp của con người. Trong xử lý ngôn ngữ tự nhiên, việc hiểu và diễn giải ẩn dụ đặt ra thách thức lớn đối với các mô hình ngôn ngữ lớn (Large Language Models – LLMs), đặc biệt đối với các ngôn ngữ giàu tính văn hóa và ngữ dụng như tiếng Việt. Tuy nhiên, các nghiên cứu và tài nguyên hiện có cho bài toán này chủ yếu tập trung vào tiếng Anh, trong khi tiếng Việt vẫn thiếu các bộ dữ liệu chuẩn hóa và benchmark công khai để đánh giá năng lực hiểu ẩn dụ một cách toàn diện.

Trong khóa luận này, chúng tôi đề xuất ViMUNCH, một bộ ngữ liệu thử thách cho bài toán hiểu ẩn dụ tiếng Việt, được xây dựng dựa trên quy trình của bộ dữ liệu MUNCH và điều chỉnh để phù hợp với đặc thù ngôn ngữ và văn hóa Việt Nam. ViMUNCH được thu thập từ nhiều nguồn văn bản đa dạng như báo chí, văn xuôi, thơ văn và diễn ngôn đời sống, nhằm đảm bảo sự phong phú về ngữ cảnh và phong cách biểu đạt. Bộ dữ liệu hỗ trợ thiết lập đa nhiệm, bao gồm: (i) nhận diện ẩn dụ, (ii) trích xuất span và phân loại loại ẩn dụ theo hướng đa nhãn, (iii) diễn giải nghĩa tường minh, và (iv) đánh giá chất lượng câu diễn giải theo rubric. Toàn bộ dữ liệu được chú thích thủ công theo quy trình nghiêm ngặt nhằm đảm bảo độ tin cậy và khả năng tái sử dụng.

Trên cơ sở ViMUNCH, chúng tôi tiến hành đánh giá bảy mô hình LLM quy mô 7–8B tham số, bao gồm các mô hình tối ưu cho tiếng Việt, các mô hình đa ngôn ngữ và mô hình đa ngôn ngữ khu vực Đông Nam Á, trong ba cấu hình: zero-shot, few-shot (5 ví dụ), fine-tuning. Fine-tuning được thực hiện bằng phương pháp SFT kết hợp LoRA để đảm bảo hiệu quả chi phí và tính công bằng so sánh. Kết quả thử nghiệm cho thấy các mô hình trong thiết lập zero-shot và few-shot vẫn dễ mắc các

lỗi mang tính hệ thống, như dự đoán nhầm ẩn dụ hoặc trích xuất span quá rộng, trong khi fine-tuning giúp cải thiện đáng kể tính nhất quán và độ phù hợp trên các nhiệm vụ có cấu trúc và rubric đánh giá. Các kết quả này cho thấy ViMUNCH là một benchmark có độ thử thách cao, phản ánh yêu cầu hiểu ngữ nghĩa sâu, đồng thời có thể đóng vai trò như benchmark đầu tiên cho bài toán hiểu ẩn dụ tiếng Việt.

Các kết quả đạt được cho thấy ViMUNCH là một bài toán khó và giàu tính ngữ nghĩa, không chỉ đòi hỏi phát hiện "có/không" mà còn yêu cầu mô hình định vị đúng biểu thức ẩn dụ, gán nhãn loại ẩn dụ (đa nhãn), diễn giải tường minh sát nghĩa và chấm điểm theo tiêu chí. Thử nghiệm cho thấy chỉ dựa vào zero-shot/few-shot, mô hình vẫn dễ mắc các lỗi mang tính hệ thống như dự đoán nhầm ẩn dụ hoặc trích span quá "rộng", trong khi fine-tuning giúp mô hình hành xử nhất quán hơn và giảm đáng kể các lỗi kiểu này. Điều đó vừa phản ánh mức độ thách thức thực tế của hiểu ẩn dụ tiếng Việt, vừa khẳng định ViMUNCH có thể đóng vai trò như một benchmark chuẩn hóa để so sánh mô hình theo nhiều khía cạnh của "hiểu nghĩa" thay vì chỉ đo bám bề mặt, đồng thời khẳng định vai trò của bộ ngữ liệu như một benchmark đầu tiên cho bài toán hiểu ẩn dụ tiếng Việt. Trên cơ sở đó, khóa luận kỳ vọng ViMUNCH sẽ trở thành nền tảng quan trọng, góp phần thúc đẩy các nghiên cứu sâu hơn về hiểu và diễn giải ẩn dụ trong tiếng Việt, cũng như hỗ trợ việc phát triển và đánh giá các mô hình ngôn ngữ lớn trong bối cảnh ngôn ngữ giàu tính hình tượng và văn hóa.

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1. Lý do chọn đề tài

Ẩn dụ là các biểu hiện ngôn ngữ dựa trên ánh xạ khái niệm giữa miền mục tiêu và miền nguồn [1]. Đây là một hiện tượng ngôn ngữ xuất hiện rất phổ biến trong cả giao tiếp hàng ngày, ngôn ngữ văn học và là cơ chế nền tảng của tư duy và giao tiếp, giúp con người hiểu, biểu đạt và hình thành cấu trúc thế giới thông qua các trải nghiệm quen thuộc và cụ thể. Vì vậy, việc hiểu ẩn dụ là một bài toán rất cần thiết cho các mô hình ngôn ngữ lớn nhằm mang lại nhiều ứng dụng và bước tiến quan trọng trong xử lý ngôn ngữ tự nhiên.

Trong bối cảnh hiện nay, việc giải quyết bài toán hiểu ẩn dụ đã đạt được nhiều đột phá với hàng loạt những nghiên cứu được triển khai cùng nhiều bộ dữ liệu được giới thiệu. VUA Corpus của Steen et al. (2010b) [2] là tập dữ liệu đánh dấu các từ liên quan đến ẩn dụ (MRWs) trong 4 triệu từ thuộc British National Corpus, tạo nền tảng cho việc xử lý nhận dạng ẩn dụ ở giai đoạn đầu. Cùng với đó, nghiên của E. Shutova (2010) [3] đã lần đầu tiên đề xuất bài toán metaphor interpretation dưới dạng paraphrasing (chuyển câu ẩn dụ thành câu literal). Tiếp theo đó là hàng loạt những bộ dữ liệu kế thừa và phát triển từ [2] được giới thiệu như MPEC – Bizzoni & Lappin (2018) [4], NewsMet – Joseph et al. (2023) [5],... Gần đây nhất, MUNCH (Tong et al., 2024) [6] là một tập dữ liệu kiểm tra khả năng hiểu ẩn dụ của các mô hình ngôn ngữ lớn thông qua bài toán chọn từ thay thế phù hợp (lexical substitution). Nhìn chung, các nghiên cứu quốc tế đã đặt nền móng cho việc hiểu và diễn giải ẩn dụ với dữ liệu như VUA, MPEC, và MUNCH, thường trên tiếng Anh.

Tuy nhiên, với tiếng Việt, việc nghiên cứu về hiểu và diễn giải ẩn dụ vẫn đang ở giai đoạn sơ khai do thiếu hụt các tài nguyên chú thích công khai. Hiện chưa có corpus lớn chuyên biệt cho nhận diện hay paraphrasing ẩn dụ tương tự VUA hay

MUNCH. Phần lớn nỗ lực đều dừng ở quy mô nhỏ, mang tính thử nghiệm nội bộ hoặc luận văn, chưa hình thành benchmark chung để so sánh mô hình. Do đó, trong nghiên cứu này, chúng tôi đã kế thừa quy trình xây dựng dữ liệu từ [6] và mở rộng thêm các nhiệm vụ bổ trợ để xây dựng bộ ngữ liệu thử thách hiểu ẩn dụ trên tiếng Việt cho các mô hình ngôn ngữ lớn (LLMs). Bộ ngữ liệu được kỳ vọng sẽ đóng góp cho những nghiên cứu sâu hơn về bài toán này trên tiếng Việt.

1.2. Thách thức

Ẩn dụ trong tiếng Việt xuất hiện ở nhiều thể loại văn bản khác nhau như tin tức, truyện ngắn, tiểu luận, diễn ngôn đời sống và đặc biệt là trong thơ văn. Các ẩn dụ này thường có cấu trúc linh hoạt, giàu tính biểu tượng và phụ thuộc vào bối cảnh văn hoá – xã hội, khiến cho việc nhận diện và diễn giải trở nên phức tạp hơn nhiều so với tiếng Anh.

Nhiều từ ngữ trong tiếng Việt có thể mang đồng thời cả nghĩa đen và nghĩa bóng, hoặc chuyển nghĩa tinh tế tùy theo ngữ cảnh. Điều này gây khó khăn không chỉ cho tác vụ phân loại (liệu câu có ẩn dụ hay không), mà còn ảnh hưởng đến độ chính xác của các tác vụ diễn giải và đánh giá diễn giải.

Hiện tại, hầu hết các nghiên cứu và tài nguyên xử lý ẩn dụ đều tập trung vào tiếng Anh. Đối với tiếng Việt, chưa có bộ dữ liệu nào vừa hỗ trợ nhận diện (identification), phân loại (classification), vừa cung cấp các diễn giải (paraphrase), đồng thời có nhãn đánh giá chất lượng diễn giải. Việc tạo mới tập dữ liệu này đòi hỏi nhiều công sức từ khâu chú thích, xác thực đến cân bằng nhãn.

Các mô hình phổ biến hiện nay như PhoBERT, XLM-R thường được huấn luyện trên văn bản thông dụng, ít tiếp xúc với các biểu đạt mang tính ẩn dụ hoặc

chuyển nghĩa cao. Do đó, khả năng phát hiện, phân biệt và diễn giải các ẩn dụ còn hạn chế – đặc biệt là các ẩn dụ ít phổ biến hoặc mang tính văn hoá nội sinh.

Dữ liệu tiếng Việt được thu thập từ nhiều nguồn: báo chí, hội thoại, tiểu luận, và cả thơ văn. Mỗi thể loại có phong cách diễn đạt khác nhau – từ ngắn gọn, chuẩn mực đến phá cách, giàu cảm xúc. Điều này gây khó khăn cho mô hình trong việc xử lý nhất quán và đánh giá chính xác giữa các tác vụ.

Không giống như dịch máy có thể so sánh với bản gốc, việc đánh giá một diễn giải ẩn dụ có "đúng" hay không phụ thuộc vào nhiều yếu tố: ngữ nghĩa, ngữ pháp, sắc thái cảm xúc, và mức độ giữ nguyên hình ảnh gốc. Điều này khiến tác vụ đánh giá (paraphrase judgement) trở thành điểm nghẽn khi chưa có bộ tiêu chí hoặc tập kiểm định chuẩn.

1.3. Mục tiêu

Trong nghiên cứu này, mục tiêu chính của chúng tôi là xây dựng bộ ngữ liệu thử thách hiểu ẩn dụ trên tiếng Việt cho các mô hình ngôn ngữ lớn (LLMs). Từ đó cung cấp benchmark đầu tiên cho bài toán hiểu ẩn dụ tiếng Việt, giúp đánh giá và so sánh hiệu năng của các mô hình ngôn ngữ lớn trên hiện tượng ngôn ngữ phức tạp này. Để làm được điều này, chúng tôi đã thu thập các mẫu văn bản tiếng Việt là các tác phẩm thơ, văn xuôi từ những nền tảng mạng xã hội phổ biến như thi viện, báo văn nghệ và thực hiện các phương pháp tiền xử lý, xây dựng tài liệu hướng dẫn gán nhãn và quy trình gán nhãn nhằm đảm bảo chất lượng của bộ dữ liệu.

1.4. Đối tượng và phạm vi nghiên cứu

Trong nghiên cứu này, chúng tôi hướng đến thử nghiệm trên các mô hình ngôn ngữ lớn (LLMs) phổ biến hiện nay. Phạm vi thực hiện nghiên cứu được triển

khai trên ngôn ngữ tiếng Việt mà cụ thể là các câu thơ, câu văn được trích từ các bài đăng, tác phẩm văn thơ, báo chí trên trang Báo Văn Nghệ.

CHƯƠNG 2: CÁC CÔNG TRÌNH LIÊN QUAN

Chương này trình bày tổng quan các hướng nghiên cứu và bộ dữ liệu liên quan đến bài toán hiểu ẩn dụ trong xử lý ngôn ngữ tự nhiên. Nội dung tập trung vào (i) các nghiên cứu nền tảng về ẩn dụ trong NLP, (ii) các bộ dữ liệu ẩn dụ theo từng ngôn ngữ, và (iii) khoảng trống nghiên cứu đối với tiếng Việt – động lực trực tiếp cho việc xây dựng bộ dữ liệu ViMUNCH trong khóa luận này.

2.1. Nghiên cứu nền tảng về hiểu ẩn dụ trong NLP

Trong NLP, các nghiên cứu ban đầu chủ yếu tập trung vào bài toán nhận diện ẩn dụ (metaphor identification), với mục tiêu phân biệt cách sử dụng nghĩa đen và nghĩa bóng của từ trong ngữ cảnh. Tiêu biểu là công trình của Steen et al. với VUA Corpus [2], đặt nền móng cho việc gán nhãn ẩn dụ ở mức từ theo giao thức MIP/MIPVU.

Sau đó, Shutova (2010) mở rộng bài toán sang hướng diễn giải ẩn dụ (metaphor interpretation), thường được mô hình hóa dưới dạng paraphrasing – chuyển câu ẩn dụ sang câu diễn đạt nghĩa tường minh. Các nghiên cứu tiếp theo như **MPEC, NewsMet** hay gần đây là MUNCH [6] đã mở rộng phạm vi từ nhận diện sang đánh giá năng lực hiểu nghĩa sâu của mô hình, đặc biệt trong bối cảnh các mô hình ngôn ngữ lớn (LLMs).

Nhìn chung, các công trình này cho thấy xu hướng chuyển dịch từ các bài toán phân loại đơn giản sang các thiết lập phức tạp hơn, yêu cầu mô hình không chỉ phát hiện ẩn dụ mà còn hiểu và diễn giải đúng nội dung ngữ nghĩa.

2.2. Các bộ dữ liệu ẩn dụ cho tiếng Anh

Như đã trình bày, những công trình nghiên cứu về bài toán hiểu ẩn dụ chủ yếu được thực hiện trên tiếng Anh . Các bộ dữ liệu chính được nhóm tham khảo

nhằm phục vụ cho việc xây dựng bộ dữ liệu ViMUNCH là MUNCH [6] và VUA Corpus [2]. MUNCH (Metaphor Understanding Challenge Dataset for LLMs) [6] do Tong et al. (2024) đề xuất là một benchmark đánh giá khả năng hiểu ẩn dụ của các mô hình ngôn ngữ lớn thông qua nhiệm vụ lexical substitution: tập chứa khoảng 3.000 câu ẩn dụ gián tiếp được trích từ VUA Corpus [2] trải bốn thể loại (học thuật, tin tức, hư cấu, hội thoại) với độ mới lạ cao, kèm hơn 10.000 diễn giải "apt" và 1.500 diễn giải "inapt" đã được chú thích thủ công để kiểm tra xem mô hình có thực sự thực hiện cross-domain mapping hay chỉ dựa vào tương đồng từ vựng. Thí nghiệm ban đầu với LLaMA và GPT-3.5 cho thấy MUNCH thực sự thách thức năng lực hiểu ẩn dụ của LLMs, từ đó gợi ý cần các phương pháp reasoning khái niệm sâu hơn khi huấn luyện hoặc thiết kế kiến trúc mô hình. MUNCH là tài nguyên quan trọng để so sánh và thúc đẩy nghiên cứu hiểu ẩn dụ, đồng thời là mẫu tham khảo cho việc xây dựng bộ dữ liệu tương tự ở ngôn ngữ khác như tiếng Việt.

Tuy nhiên, MUNCH cũng có một số hạn chế cần lưu ý: (1) chỉ tập trung vào ẩn dụ gián tiếp trong tiếng Anh; (2) quy mô tương đối khiêm tốn (~3.000 câu) và chủ yếu dựa trên VUA Corpus, có thể chưa đủ đa dạng ngữ cảnh hoặc miền chủ đề; (3) nhiệm vụ chỉ xét lexical substitution đơn từ, chưa mở rộng sang diễn giải phức tạp hoặc diễn giải chi tiết cấu trúc ánh xạ khái niệm; (4) annotation đôi khi mang tính chủ quan và không cung cấp giải thích chi tiết về lý do chọn diễn giải apt/inapt; (5) không xét đến khía cạnh khác biệt văn hóa hay ngữ dụng sâu; (6) chỉ áp dụng cho tiếng Anh, chưa tương thích trực tiếp với các ngôn ngữ khác.

Bên cạnh VUA Corpus, MOH Dataset tập trung vào các động từ có tính đa nghĩa cao, phù hợp cho phân tích chi tiết sự chuyển nghĩa giữa cách dùng literal và metaphorical, qua đó hỗ trợ đánh giá năng lực phân biệt ngữ nghĩa tinh của mô hình [26]. Trong khi đó, TroFi là một bộ dữ liệu được đề xuất sớm hơn, đóng vai trò nền

tảng trong các nghiên cứu phân biệt nghĩa đen và nghĩa bóng của động từ trong văn bản báo chí [27].

Ngoài các corpus truyền thống, LCC Metaphor Datasets cung cấp anotations với quy mô lớn và trải rộng trên nhiều miền dữ liệu, cho phép nghiên cứu mức độ ẩn dụ (metaphoricity scoring) thay vì chỉ dừng lại ở phân loại nhị phân [28]. Những bộ dữ liệu này góp phần định hình các hướng tiếp cận đa dạng cho bài toán hiểu ẩn dụ trong tiếng Anh.

2.3. Các bộ dữ liệu ẩn dụ cho tiếng Tây Ban Nha và nghiên cứu song ngữ

Đối với tiếng Tây Ban Nha, CoMeta Corpus là một trong những bộ dữ liệu tiêu biểu, được xây dựng nhằm hỗ trợ bài toán phát hiện ẩn dụ trong bối cảnh đa miền và phục vụ nghiên cứu so sánh liên ngôn ngữ [29]. Song song đó, Meta4XNLI là một bộ dữ liệu song ngữ Anh – Tây Ban Nha, tích hợp hiện tượng ẩn dụ vào khung bài toán suy luận ngôn ngữ tự nhiên (Natural Language Inference – NLI) [30]. Cách tiếp cận này cho phép đánh giá khả năng hiểu và diễn giải ẩn dụ của mô hình trong các thiết lập cross-lingual, đồng thời mở rộng nghiên cứu ẩn dụ sang các nhiệm vụ suy luận ngữ nghĩa phức tạp hơn.

2.4. Các bộ dữ liệu ẩn dụ cho tiếng Trung

So với tiếng Anh, các bộ dữ liệu ẩn dụ tiếng Trung xuất hiện muộn hơn nhưng phát triển nhanh, đặc biệt theo hướng mở rộng phạm vi biểu đạt. Chinese Metaphor Corpus (CMC) là một trong những tài nguyên văn bản thuần sớm nhất, hỗ trợ các nhiệm vụ phát hiện và sinh ẩn dụ trong tiếng Trung [31]. Gần đây, các bộ dữ liệu như CM3D và MultiMM mở rộng nghiên cứu sang hướng kết hợp văn bản

và hình ảnh, đồng thời xem xét yếu tố văn hóa trong cách sử dụng và diễn giải ẩn dụ giữa các ngôn ngữ khác nhau [32], [33].

2.5. Các bộ dữ liệu ẩn dụ đa phương thức

Song song với các bộ dữ liệu văn bản, hướng nghiên cứu hiểu ẩn dụ đa phương thức ngày càng được quan tâm. MultiMET là một trong những bộ dữ liệu tiên phong, kết hợp văn bản và hình ảnh để nghiên cứu cách ẩn dụ được biểu đạt đồng thời qua nhiều kênh thông tin [34]. Bộ dữ liệu này cho phép đánh giá khả năng tích hợp ngữ nghĩa của mô hình khi xử lý các biểu thức ẩn dụ không chỉ tồn tại trong ngôn ngữ mà còn trong hình ảnh minh họa, qua đó đặt ra thách thức mới cho các mô hình học sâu và LLMs trong việc liên kết tri thức thị giác với suy luận ngôn ngữ trừu tượng.

2.6. Các bộ dữ liệu ẩn dụ cho ngôn ngữ ít tài nguyên

Ngoài các ngôn ngữ phổ biến, một số nghiên cứu gần đây đã bắt đầu xây dựng bộ dữ liệu ẩn dụ cho các ngôn ngữ ít tài nguyên. Nepali Metaphor Corpus là một ví dụ tiêu biểu, với anotations ở mức câu nhằm phục vụ bài toán phát hiện ẩn dụ trong tiếng Nepal [35]. Mặc dù quy mô còn hạn chế, các bộ dữ liệu dạng này đóng vai trò quan trọng trong việc đánh giá khả năng tổng quát hóa và chuyển giao tri thức của các mô hình ngôn ngữ đa ngữ, đồng thời làm nổi bật sự mất cân đối tài nguyên giữa các ngôn ngữ trong nghiên cứu NLP.

2.7. Khoảng trống nghiên cứu và vị trí của ViMUNCH

Tổng hợp các công trình và bộ dữ liệu hiện có cho thấy phần lớn nghiên cứu về hiểu ẩn dụ vẫn tập trung vào tiếng Anh và một số ngôn ngữ có tài nguyên phong phú. Đối với tiếng Việt, hiện chưa có bộ dữ liệu công khai nào vừa hỗ trợ nhận diện ẩn dụ, vừa cung cấp diễn giải, đồng thời có nhãn đánh giá chất lượng diễn giải theo

tiêu chí rõ ràng. Khoảng trống này hạn chế khả năng đánh giá và so sánh công bằng các mô hình ngôn ngữ lớn trong bối cảnh tiếng Việt.

Vì vậy, chúng tôi đã kế thừa quy trình xây dựng bộ dữ liệu MUNCH để xây dựng ViMUNCH cho tiếng Việt, đồng thời mở rộng thêm các nhiệm vụ: đa dạng hóa nguồn dữ liệu và ngữ cảnh đặc thù tiếng Việt; xây dựng diễn giải phức tạp hơn vượt lên lexical substitution đơn thuần, phân loại ẩn dụ; chú trọng khía cạnh văn hóa và ngữ dụng Việt.

CHƯƠNG 3: XÂY DỰNG BỘ DỮ LIỆU

Chương 3 trình bày chi tiết quy trình xây dựng bộ dữ liệu ViMUNCH – nền tảng quan trọng nhất để triển khai các thí nghiệm trong các chương sau. Như minh họa ở hình 3.1, toàn bộ pipeline được thiết kế theo hai pha chính: (1) tiền xử lý & tuyển chọn dữ liệu từ nguồn văn bản thô, và (2) gán nhãn theo hướng human-in-the-loop nhằm đảm bảo chất lượng và tính nhất quán.

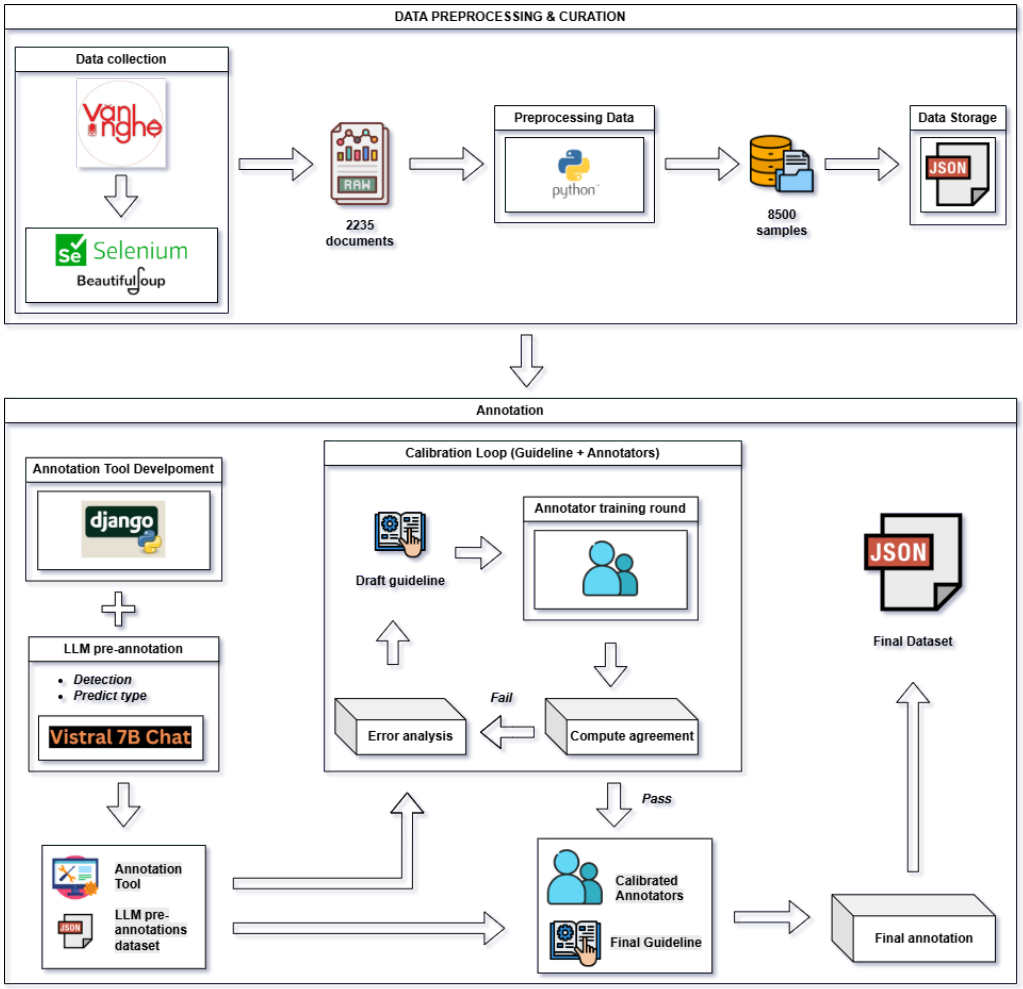

Hình 3.1: Tổng quan quy trình xây dựng ViMUNCH

3.1. Định nghĩa các nhiệm vụ

3.1.1. Nhận diện ẩn dụ (Metaphor Identification)

Bài toán yêu cầu phát hiện một câu văn cho trước có ẩn dụ hay không.

Đầu vào: Câu văn sau khi đã thu thập và tiền xử lý.

Đầu ra: Nhãn 0 (Không có ẩn dụ) hoặc 1 (Có ẩn dụ). Trường hợp nhãn 1, trích xuất danh sách các từ/cụm từ chứa ẩn dụ kèm vị trí bắt đầu và vị trí kết thúc của các span đó trong câu.

Ví dụ:

Bảng 3.1: Ví dụ minh họa cho nhiệm vụ nhận diện câu chứa ẩn dụ

Đầu vào	Đầu ra	Giải thích
"Sự huyền bí của rừng cây Mãi còn là một bậc thầy cao sâu"	{ "sentence": "Sự huyền bí của rừng cây Mãi còn là một bậc thầy cao sâu", "have_metaphor": 1, "metaphor_phrases": [["Sự huyền bí của rừng cây", 0, 23], ["Mãi còn là một bậc thầy cao sâu", 25, 55]], "metaphor_types": ["structural", "emotional"] }	Câu văn sử dụng ẩn dụ bản thể (ontological metaphor) khi gán cho "sự huyền bí của rừng cây" — một khái niệm trừu tượng — thuộc tính và vai trò của con người ("một bậc thầy cao sâu"). Cách nhân hóa này biến cái trừu tượng thành một thực thể có trí tuệ, có khả năng "dạy dỗ", nên câu được gán nhãn có ẩn dụ (have_metaphor = 1).

3.1.2. Diễn giải và phân loại ẩn dụ (Metaphor Interpretation & Classification)

Bài toán yêu cầu diễn giải lại câu chứa ẩn dụ sao cho không làm thay đổi ý nghĩa của câu gốc. Sau đó phân loại xem phép ẩn dụ trong câu thuộc loại ẩn dụ nào.

Đầu vào: Câu văn có chứa ẩn dụ.

Đầu ra: Câu văn diễn đạt lại ý của câu văn chứa ẩn dụ, trong đó phần ẩn dụ được diễn giải dễ hiểu hơn và các nhãn phân loại tương ứng với 5 loại ẩn dụ, trong đó có 3 loại ẩn dụ được xây dựng theo lý thuyết của Lakoff & Johnson, và 2 loại ẩn dụ được nhóm tác giả bổ sung dựa trên đặc điểm văn hóa và ngôn ngữ tiếng Việt (Bảng 3.2).

Bảng 3.2: Hệ thống các loại ẩn dụ được sử dụng trong bộ dữ liệu ViMUNCH

Loại ẩn dụ	Mô tả	Ví dụ
Ẩn dụ cấu trúc (Lakoff & Johnson)	Một lĩnh vực khái niệm được cấu trúc hóa theo một lĩnh vực khác, giúp người đọc hiểu khái niệm phức tạp thông qua khái niệm quen thuộc.	*"Cuộc đời là một sân khấu, và chúng ta đều là những kịch sỹ." ("As You Like It" - Shakespeare, bản dịch tiếng Việt)* - "cuộc đời" được ví như "sân khấu", con người là "diễn viên" phải thực hiện vai trò của mình
Ẩn dụ định hướng (Lakoff & Johnson)	Diễn tả các khái niệm trừu tượng thông qua phương hướng không gian (lên/xuống, vào/ra, trước/sau), giúp định hình giá trị tích cực hay tiêu cực.	*"Lên non mới biết non cao" (Ca dao Việt Nam)* - Ẩn dụ định hướng "lên" biểu thị sự tiến bộ, phát triển hoặc đạt được mục tiêu cao hơn.

Ẩn dụ bản thể (Lakoff & Johnson)	Xem các khái niệm trừu tượng như vật thể hữu hình hoặc sinh thể, giúp dễ dàng hình dung và tác động đến.	*"Hồn tôi là một vườn hoa lá, Rất đậm hương và rộn tiếng chim " ("Từ ấy" – Tố Hữu)* - "tâm hồn" được ví như "vườn hoa" tràn đầy sức sống
Ẩn dụ văn hóa dân gian (bổ sung)	Ẩn dụ bắt nguồn từ kinh nghiệm tập thể, truyền thống và văn hóa dân gian, từ đó phản ánh sâu sắc thế giới quan và kinh nghiệm sống của cộng đồng người Việt, tạo nên bản sắc riêng trong ngôn ngữ.	*"Thân em như hạt mưa sa, hạt vào đài các hạt ra ruộng cày." (Ca dao Việt Nam)* - so sánh thân phận người phụ nữ với hạt mưa rơi, thể hiện sự nhỏ bé, lênh đênh không được làm chủ số phận mình.
Ẩn dụ cảm xúc (bổ sung)	Biểu đạt tinh tế trạng thái tình cảm, cảm xúc con người thông qua những hình ảnh cụ thể, giàu sức gợi. Đây cũng là nét đặc trưng nổi bật của tiếng Việt— giàu tính biểu cảm.	*"Buồn trông cửa bể chiều hôm, Thuyền ai thấp thoáng cánh buồm xa xa." ("Truyện Kiều" – Nguyễn Du)* - Hình ảnh con thuyền thấp thoáng như hy vọng mong manh, xa vời, thể hiện khát khao tự do và nỗi tuyệt vọng dần lớn lên trong lòng Kiều.

Ví dụ:

Bảng 3.3: Ví dụ minh họa cho nhiệm vụ diễn giải và phân loại ẩn dụ

Đầu vào	**Đầu ra**	**Giải thích**
"Đêm tối dày đặc, ngõ con hẻm vào làng lại càng đen sẫm hơn nữa như cái hang không đáy." ("Hai đứa trẻ" - Thạch Lam)	• *"Đêm tối dày đặc bao trùm khắp phố huyện, con ngõ nhỏ dẫn vào làng càng trở nên đen sẫm, hun hút như lối đi vào một thế giới tăm tối, không có điểm dừng."* • Ontological (Ẩn dụ bản thể) và Emotional (Ẩn dụ cảm xúc)	• **Ontological metaphor (Ẩn dụ bản thể):** "đêm tối dày đặc", "cái hang không đáy", "lối đi vào một thế giới tăm tối" biến những khái niệm trừu tượng (bóng tối, không gian mơ hồ) thành thực thể có hình khối, độ sâu, ranh giới, giúp người đọc "nhìn thấy" và "bước vào" bóng tối như một vật thể cụ thể. • **Emotional metaphor (Ẩn dụ cảm xúc):** Hình ảnh "hun hút", "không có điểm dừng", "thế giới tăm tối" không chỉ miêu tả không gian vật lý mà còn gợi cảm giác ngột ngạt, bế tắc, u buồn, phản ánh trạng thái cảm xúc trầm lắng và mòn mỏi của con người nơi phố huyện về đêm.

3.1.3. Đánh giá câu diễn giải (Paraphrase Judgement)

Bài toán yêu cầu xác định chất lượng gán nhãn và mức độ tương đồng về ý nghĩa giữa một câu chứa ẩn dụ và câu diễn giải của nó.

Đầu vào: Một câu văn có chứa ẩn dụ với câu diễn giải nhằm thể hiện lại ý nghĩa gốc của câu gốc.

Đầu ra: Điểm tổng đánh giá chất lượng diễn giải và độ tương đồng giữa hai câu.

Ví dụ:

Bảng 3.4: Ví dụ minh họa cho nhiệm vụ đánh giá chất lượng diễn giải ẩn dụ

Đầu vào	Đầu ra	Giải thích
• **Câu gốc:** *"Thuyền về có nhớ bến chăng? Bến thì một dạ khăng khăng đợi thuyền."* • **Câu diễn giải:** *"Người đi có còn nhớ chốn cũ? Chốn cũ vẫn luôn thủy chung chờ đợi."*	• **Điểm tổng chất lượng diễn giải:** 4. • **Điểm tổng độ tương đồng:** 3.8.	Câu diễn giải giữ trọn nội dung, cảm xúc và hàm ý thủy chung của câu gốc; chỉ giảm nhẹ đặc trưng nhịp điệu thơ, không ảnh hưởng ý nghĩa tổng thể.

3.2. Thu thập, tiền xử lý dữ liệu

Nghiên cứu tiến hành thu thập các mẫu văn bản tiếng Việt từ trang Báo Văn Nghệ bằng cách kết hợp Selenium và BeautifulSoup, tập trung vào các thể loại giàu tính hình tượng như bài đăng, thơ và văn xuôi. Quá trình thu thập thu được **2.235 mẫu văn bản thô**, sau đó được tiền xử lý thông qua các bước chuẩn hóa văn bản, loại bỏ ký tự đặc biệt, lọc câu không phải tiếng Việt và tách câu.

Trong đó, tách câu được xem là bước then chốt và cũng là thách thức chính do đặc trưng của văn bản tiếng Việt, đặc biệt với thơ và văn bản mang tính thơ (poetic/prosa-poetic). Các phương pháp tách câu dựa thuần vào dấu câu thường hoạt động kém hiệu quả trong các trường hợp này. Do đó, nghiên cứu đề xuất một phương pháp tách câu tự động kết hợp heuristic có kiểm soát, cho phép phân biệt giữa thơ và văn xuôi, từ đó áp dụng chiến lược xử lý phù hợp.

Đối với văn xuôi, hệ thống sử dụng các dấu kết thúc câu phổ biến trong tiếng Việt (., !, ?, …) làm tín hiệu chính, đồng thời bổ sung các cơ chế kiểm soát ngữ cảnh nhằm hạn chế lỗi tách sai. Cụ thể, câu không bị tách khi dấu câu xuất hiện bên trong ngoặc hoặc dấu trích dẫn; các trường hợp dấu chấm không mang chức năng kết thúc câu như số thập phân (ví dụ 3.14) hoặc viết tắt thông dụng (PGS., TS.) cũng được loại trừ. Chuỗi nhiều dấu chấm được xử lý như một đơn vị kết thúc duy nhất để tránh hiện tượng tách dư thừa. Sau khi tách, các câu chứa trích dẫn được ghép và chuẩn hóa lại nhằm đảm bảo tính toàn vẹn ngữ nghĩa.

Đối với văn bản thơ, hệ thống sử dụng hàm nhận diện dựa trên đặc trưng hình thức, bao gồm số dòng hợp lệ, tỉ lệ dòng ngắn (không quá 8 từ) và mối tương quan giữa số dòng và số dấu kết thúc câu. Một văn bản được coi là thơ nếu thỏa mãn các ngưỡng phản ánh đặc trưng phổ biến của thơ tiếng Việt: xuống dòng thường xuyên và ít sử dụng dấu câu. Với các trường hợp thơ có ít dấu kết thúc câu, hệ thống áp dụng chiến lược xử lý riêng, trong đó các dòng thơ ngắn được ghép có kiểm soát (tối đa hai dòng liên tiếp) để tạo thành các câu có độ dài phù hợp, đồng thời hạn chế làm mất cấu trúc ý nghĩa.

Sau khi thu được danh sách câu từ cả hai nhánh xử lý, hệ thống thực hiện hậu xử lý nhằm đảm bảo chất lượng dữ liệu: loại bỏ các câu chỉ chứa ký tự đặc biệt hoặc chữ số, loại các câu quá dài (trên 500 từ), loại trùng lặp và áp dụng phát hiện ngôn

ngữ để giữ lại các câu tiếng Việt. Kết quả cuối cùng là một bộ dữ liệu thô gồm 8.501 mẫu câu, trong đó mỗi mẫu được xây dựng sao cho vẫn bảo toàn ngữ cảnh gốc ở mức tối đa.

Phương pháp đề xuất cho thấy ưu điểm nổi bật trong việc xử lý văn bản thơ tiếng Việt nhờ khả năng phân biệt thơ và văn xuôi bằng các chỉ số hình thức đơn giản nhưng hiệu quả, kết hợp với cơ chế ghép dòng có kiểm soát. Việc xử lý tinh tế các trường hợp dấu chấm trong số, viết tắt, dấu ba chấm và trạng thái ngoặc giúp giảm đáng kể lỗi tách câu sai. Tuy nhiên, phương pháp vẫn tồn tại một số hạn chế, bao gồm danh sách viết tắt còn hạn chế, độ nhạy với chữ hoa–chữ thường, nguy cơ nhận diện nhầm một số dạng thơ hiện đại, và việc chưa bảo toàn thông tin vị trí gốc của câu trong văn bản.

Phương pháp được đánh giá trên một tập gồm 3.000 câu dự đoán và 3.000 câu chuẩn, **đạt Precision, Recall và F1-score xấp xỉ 0.72**, với hơn **1.700 câu trùng khớp hoàn toàn và gần 400 câu tương đương về mặt ngữ nghĩa**. Kết quả này cho thấy phương pháp đạt hiệu quả tương đối tốt, đặc biệt trong bối cảnh xử lý văn bản thơ tiếng Việt vốn giàu tính hình thức và ngữ nghĩa.

3.3. Gán nhãn dữ liệu

3.3.1. Công cụ gán nhãn

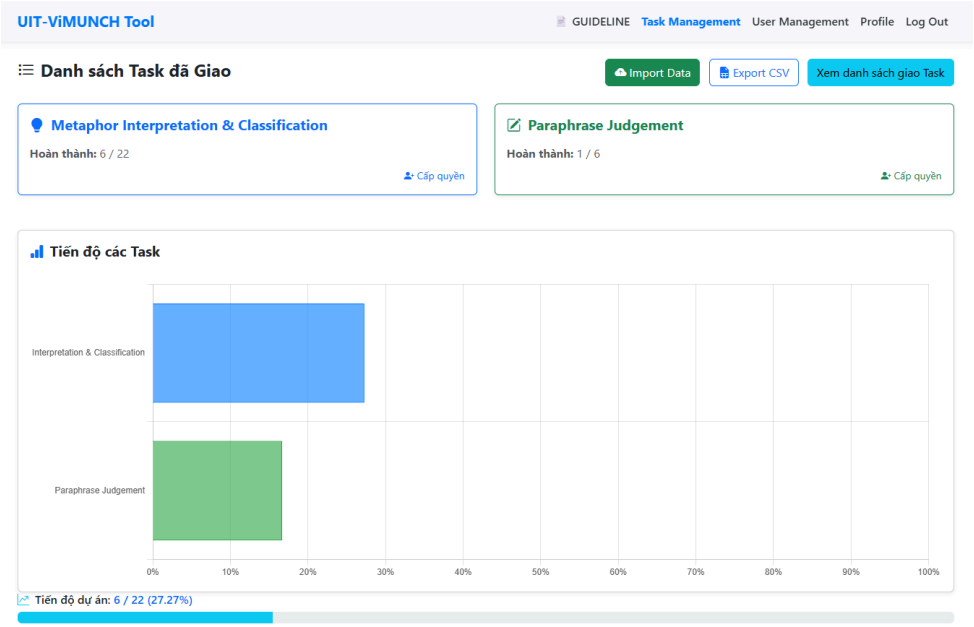

Hình 3.2: Giao diện trang chủ của công cụ gán nhãn hỗ trợ chú thích ẩn dụ tiếng Việt

Nghiên cứu phát triển một công cụ gán nhãn chuyên biệt cho bài toán chú thích ẩn dụ trong thơ và văn xuôi tiếng Việt, được triển khai trên nền tảng Django (Python) với giao diện web, cho phép annotator truy cập và làm việc từ xa. Thiết kế này nhằm đảm bảo tính linh hoạt, khả năng mở rộng và phù hợp với yêu cầu chú thích học thuật của đề tài.

Về mặt chức năng, công cụ hỗ trợ đầy đủ các nhiệm vụ diễn giải và phân loại ẩn dụ. Giao diện hiển thị trực tiếp văn bản cần gán nhãn, cho phép annotator nhập câu diễn giải và lựa chọn loại ẩn dụ tương ứng. Các biểu thức ẩn dụ (span) được hệ thống tự động làm nổi bật, kèm theo các gợi ý ban đầu do mô hình LLM đề xuất. Annotator có thể chỉnh sửa hoặc thay thế các gợi ý này, đặc biệt trong các trường

hợp câu có nhiều tầng ngữ nghĩa hoặc cấu trúc ẩn dụ phức tạp, qua đó đảm bảo chất lượng và độ chính xác của nhãn.

Để kiểm soát chất lượng chú thích, hệ thống hỗ trợ đánh giá độc lập hai chiều. Annotator thứ hai thực hiện đánh giá trên hai khía cạnh: (i) chất lượng diễn giải, xét theo các tiêu chí về độ chính xác, tính rõ ràng và mức độ tự nhiên; và (ii) độ tương đồng ngữ nghĩa giữa câu gốc và câu diễn giải, dựa trên nhiều thành phần ngữ nghĩa và ngữ dụng. Các điểm đánh giá được hệ thống tự động tổng hợp theo công thức chuẩn hóa, giúp giảm sai lệch chủ quan và đảm bảo tính nhất quán giữa các annotator.

Về quản lý dữ liệu, công cụ hỗ trợ nhập và xuất dữ liệu ở định dạng JSON chuẩn, phù hợp cho các bước huấn luyện, tinh chỉnh và đánh giá mô hình NLP. Cấu trúc dữ liệu được thiết kế thống nhất, cho phép dễ dàng mở rộng và tái sử dụng trong các nghiên cứu tiếp theo.

Toàn bộ quy trình gán nhãn được tích hợp trong một pipeline có kiểm soát, bao gồm phân phối dữ liệu, gán nhãn ban đầu, đánh giá chéo và chuẩn hóa đầu ra. Hệ thống đồng thời hỗ trợ quản lý annotator thông qua cơ chế tài khoản cá nhân và phân quyền rõ ràng, cho phép theo dõi tiến độ, phân phối nhiệm vụ và thống kê kết quả một cách minh bạch.

Nhìn chung, công cụ gán nhãn được thiết kế không chỉ để phục vụ riêng cho bộ dữ liệu ViMUNCH mà còn hướng tới khả năng tái sử dụng như một nền tảng chú thích ẩn dụ cho tiếng Việt, góp phần nâng cao độ tin cậy và tính chuẩn hóa của dữ liệu trong các nghiên cứu NLP liên quan.

3.3.2. Hướng dẫn gán nhãn

Việc gán nhãn dữ liệu trong nghiên cứu này được tổ chức xoay quanh ba tác vụ chính, bao gồm: diễn giải ẩn dụ, phân loại ẩn dụ và đánh giá câu diễn giải. Trong đó, hai tác vụ diễn giải và phân loại được gộp thành một công đoạn thống nhất, nhằm đảm bảo annotator xử lý ẩn dụ một cách toàn diện, vừa làm rõ ý nghĩa vừa xác định đúng loại hình ẩn dụ được sử dụng. Toàn bộ quá trình được điều phối dựa trên một bộ guideline chi tiết, đóng vai trò trung tâm trong việc đảm bảo tính nhất quán, khả năng tái lập và độ tin cậy của dữ liệu gán nhãn.

Diễn giải ẩn dụ (Metaphor Interpretation)

Tác vụ diễn giải ẩn dụ yêu cầu người gán nhãn viết lại câu gốc sao cho phần biểu đạt mang tính ẩn dụ trở nên tường minh, cụ thể và dễ hiểu hơn, hướng đến đối tượng người đọc phổ thông, không đòi hỏi kiến thức chuyên môn về văn học hay ngôn ngữ học. Mục tiêu của diễn giải không phải là phân tích hay bình luận, mà là làm lộ rõ nội dung ý nghĩa được che phủ bởi ẩn dụ.

Cụ thể, annotator cần thay thế các cụm từ mang tính ẩn dụ hoặc, trong trường hợp cần thiết, diễn giải lại toàn bộ câu bằng biểu đạt trực tiếp hơn. Trong quá trình này, ý nghĩa mệnh đề của câu gốc phải được bảo toàn, tuyệt đối tránh việc thêm thắt suy diễn chủ quan hoặc làm lệch hướng thông điệp ban đầu. Câu diễn giải được yêu cầu có độ dài hợp lý, đúng ngữ pháp tiếng Việt và có văn phong tự nhiên, mạch lạc.

Phân loại ẩn dụ (Metaphor Classification)

Song song với diễn giải, annotator thực hiện phân loại ẩn dụ xuất hiện trong câu dựa trên hệ thống phân loại đã được thống nhất trong guideline. Các loại ẩn dụ chính được sử dụng trong nghiên cứu bao gồm: ẩn dụ cấu trúc, ẩn dụ định hướng, ẩn dụ bản thể, ẩn dụ cảm xúc và ẩn dụ văn hóa dân gian.

Trong trường hợp một câu thể hiện nhiều lớp ẩn dụ chồng lấn, hệ thống cho phép annotator gán nhiều nhãn đồng thời, phản ánh đúng bản chất phức hợp của hiện tượng ngôn ngữ. Việc phân loại được thực hiện dựa trên cơ chế ánh xạ giữa miền nguồn và miền đích, cũng như chức năng biểu đạt của ẩn dụ trong ngữ cảnh cụ thể.

Đánh giá câu diễn giải

Sau khi hoàn tất công đoạn diễn giải và phân loại ẩn dụ, mỗi câu diễn giải được chuyển sang bước đánh giá độc lập nhằm kiểm soát chất lượng chú thích và mức độ bảo toàn ý nghĩa so với câu gốc. Hoạt động đánh giá này đóng vai trò quan trọng trong việc đảm bảo độ tin cậy nội tại của bộ dữ liệu, đồng thời cung cấp các chỉ số định lượng phục vụ phân tích và huấn luyện mô hình.

Việc đánh giá được tiến hành trên hai khía cạnh chính: (i) *chất lượng của câu diễn giải* và (ii) *mức độ tương đồng ngữ nghĩa giữa câu gốc và câu diễn giải*.

(i) *chất lượng của câu diễn giải*

Chất lượng của câu diễn giải được đánh giá dựa trên ba tiêu chí cơ bản, phản ánh mức độ phù hợp của diễn giải đối với mục tiêu làm rõ ẩn dụ mà không làm sai lệch nội dung ban đầu.

Thứ nhất, **độ chính xác (Accuracy)** đo lường mức độ giữ nguyên ý nghĩa cốt lõi của câu gốc. Một câu diễn giải được xem là chính xác khi phản ánh đúng nội dung mệnh đề và hàm ý của ẩn dụ, không thêm thắt suy diễn chủ quan, cũng không làm mất hoặc làm lệch thông tin quan trọng. Thang điểm đề xuất (0-4) cho tiêu chí này như sau:

- **4 điểm:** Câu diễn giải giữ nguyên hoàn toàn ý nghĩa của câu gốc, không có thông tin thừa hoặc thiếu.
- **3 điểm:** Câu diễn giải bám sát ý chính của câu gốc, chỉ mất đi một phần nhỏ sắc thái nhưng không ảnh hưởng đến ý tổng thể.
- **2 điểm:** Câu diễn giải truyền tải được ý nghĩa cơ bản nhưng bỏ sót hoặc hiểu sai một phần nhỏ.
- **1 điểm:** Câu diễn giải có sự sai lệch đáng kể về ý nghĩa so với câu gốc.
- **0 điểm:** Câu diễn giải hoàn toàn thay đổi hoặc làm mất đi ý nghĩa ban đầu.

<u>Ví dụ:</u>

- **Câu gốc:** *"Lửa thử vàng, gian nan thử sức."*
- **4 điểm:** *"Khó khăn, thử thách tạo cơ hội để con người thể hiện bản lĩnh và sức mạnh thực sự của mình"*
- **3 điểm:** *"Con người chỉ thể hiện bản lĩnh và sức mạnh thực sự khi đối mặt với khó khăn."* (Bám sát ý chính của câu những chưa truyền tải được đầy đủ từ ẩn dụ "thử" – tượng trưng cho việc khó khăn là cơ hội để bộc lộ bản lĩnh và sức mạnh thực sự của bản thân)
- **2 điểm:** *"Khó khăn, thử thách giúp con người mạnh mẽ hơn."* (Truyền tải được ý nghĩa cơ bản những thiếu đi yếu tố "lửa" và "vàng" là ẩn dụ cho khó khăn thử thách và phẩm chất, bản lĩnh con người)
- **1 điểm:** *"Những khó khăn, thử thách chỉ khiến con người thêm nản chí và mất đi bản lĩnh."* (Diễn giải sai lệch đáng kể ý nghĩa của câu gốc)

- **0 điểm:** *"Khó khăn, thử thách lấy đi cơ hội thể hiện bản lĩnh và sức mạnh thực sự của con người."* (Diễn giải sai lệch hoàn toàn ý nghĩa của câu gốc)

Thứ hai, **độ rõ ràng (Clarity)** phản ánh mức độ dễ hiểu của câu diễn giải đối với người đọc phổ thông. Câu diễn giải cần sử dụng từ ngữ trực tiếp, mạch lạc, tránh cấu trúc tối nghĩa hoặc vòng vo, đặc biệt là tránh việc tạo ra các biểu đạt mới tiếp tục mang tính ẩn dụ. Thang điểm đề xuất (0-4) cho tiêu chí này như sau:

- **4 điểm:** Câu diễn giải rõ ràng, dễ hiểu, truyền tải trọn vẹn ý nghĩa và giải thích được ẩn dụ.
- **3 điểm:** Câu diễn giải dễ hiểu, chỉ còn thiếu hoặc diễn đạt chưa rõ một hoặc một vài hình ảnh cần diễn đạt.
- **2 điểm:** Câu diễn giải có phần sáng tỏ nhưng vẫn tồn tại vài điểm mơ hồ hoặc khó hiểu.
- **1 điểm:** Câu diễn giải thiếu rõ ràng, người đọc phải suy đoán nhiều.
- **0 điểm:** Câu diễn giải chung chung, rối rắm, khó hiểu, thậm chí còn phức tạp hơn cả câu gốc.

<u>Ví dụ:</u>

- **Câu gốc:** *"Công cha như núi Thái Sơn, nghĩa mẹ như nước trong nguồn chảy ra."*
- **4 điểm:** *"Công lao của cha to lớn và vững vàng như ngọn núi cao, còn tình thương của mẹ thì dạt dào, bền bỉ như dòng nước mát lành chảy mãi không ngừng."*

- **3 điểm:** *"Công lao của cha to lớn và vững vàng, còn tình thương của mẹ thì dạt dào, bền bỉ."*(thiếu hình ảnh "núi Thái Sơn" và "nước trong nguồn chảy ra" để làm rõ hơn ý nghĩa ẩn dụ)
- **2 điểm:** *"Công lao của cha to lớn và vững vàng như ngọn núi cao, còn tình thương của mẹ thì như dòng nước mát lành chảy mãi không ngừng."* (Chỉ sáng tỏ phần "Công cha như núi Thái Sơn", phần "Nghĩa mẹ...chảy ra" chưa rõ)
- **1 điểm:** *" Công lao của cha như ngọn núi cao, còn tình thương của mẹ như dòng nước mát lành chảy mãi không ngừng "* (Thiếu đi sự giải thích cụ thể cho hình ảnh ẩn dụ "núi Thái Sơn" và "nước trong nguồn", dẫn đến sự khó hiểu, chưa rõ ràng)
- **0 điểm:** *"Cha mẹ yêu thương con cái rất nhiều."* (Diễn giải quá chung chung, mất hoàn toàn sự cụ thể và tinh tế của câu gốc)

Thứ ba, **độ tự nhiên (Naturalness)** đánh giá mức độ trôi chảy, đúng ngữ pháp và phù hợp với phong cách tiếng Việt thông thường. Tiêu chí này nhằm đảm bảo câu diễn giải không mang cảm giác gượng ép, máy móc hay giống văn bản dịch tự động. Thang điểm đề xuất (0-4) cho tiêu chí này như sau:

- **4 điểm:** Câu diễn giải trôi chảy, giữ được cảm xúc văn học và nét biểu cảm tự nhiên.
- **3 điểm:** Câu diễn giải mượt mà, chỉ thiếu một chút tinh tế, cụ thể về mặt cảm xúc.
- **2 điểm:** Câu diễn giải rõ ý nhưng văn phong hơi gượng gạo.
- **1 điểm:** Câu diễn giải cứng nhắc, mang tính giải thích khô khan.
- **0 điểm:** Câu diễn giải vụng về, mất đi hoàn toàn sự mượt mà tự nhiên.

Ví dụ:

- **Câu gốc:** *"Người con gái ấy như bông hoa rừng nở giữa núi cao."*
- **4 điểm:** *"Người con gái ấy mang vẻ đẹp trong trẻo, giản dị như đóa hoa nở giữa núi rừng hoang sơ."*
- **3 điểm:** *"Người con gái ấy đẹp như đóa hoa nở giữa núi rừng hoang sơ."*
- **2 điểm:** *"Cô ấy đẹp như bông hoa mọc trong rừng."* (Mất đi nét biểu cảm và sự mượt mà của câu văn)
- **1 điểm:** *"Cô ấy đẹp như hoa trong rừng trên núi cao"* (Câu diễn giải cứng nhắc, mang tính giải thích khô khan)
- **0 điểm:** *"Cô ấy đẹp như hoa trong rừng rất cao."* (Câu diễn giải thô cứng, không tự nhiên)

Mỗi tiêu chí được chấm theo thang điểm từ 0 đến 4, trong đó 0 thể hiện mức không đạt yêu cầu và 4 thể hiện mức rất tốt. Điểm chất lượng tổng hợp được hệ thống tính tự động theo công thức có trọng số như sau:

$$\text{Điểm tổng} = \frac{3 \times \text{Độ } chính\ xác + 2 \times \text{Độ } rõ\ ràng + \text{Độ } tự\ nhiên}{6} \quad (3.1)$$

Trong công thức 3.1, độ chính xác được nhân hệ số 3 do đây là tiêu chí quan trọng nhất, quyết định giá trị ngữ nghĩa của dữ liệu. Độ rõ ràng được nhân hệ số 2 nhằm đảm bảo câu diễn giải dễ tiếp cận đối với người đọc. Độ tự nhiên mang hệ số 1, đóng vai trò khuyến khích văn phong mạch lạc nhưng không được phép lấn át tính chính xác.

(ii) ***mức độ tương đồng ngữ nghĩa giữa câu gốc và câu diễn giải***

Bên cạnh chất lượng nội tại, câu diễn giải còn được đánh giá về mức độ tương đồng ngữ nghĩa so với câu gốc. Khía cạnh này nhằm đo lường mức độ bảo toàn ý nghĩa sau khi chuyển đổi từ biểu đạt ẩn dụ sang biểu đạt tường minh.

Việc đánh giá được thực hiện dựa trên năm tiêu chí, mỗi tiêu chí phản ánh một tầng nghĩa khác nhau của ngôn ngữ:

- **Nghĩa mệnh đề (30%):** mức độ trùng khớp về nội dung thông tin cốt lõi mà câu truyền tải. Ví dụ:
- **Hàm ý (25%):** mức độ giữ lại ý nghĩa ngầm, giá trị biểu trưng hoặc thông điệp ẩn phía sau câu.
- **Nghĩa tình thái (25%):** mức độ bảo toàn thái độ, cảm xúc hoặc lập trường của người nói/viết.
- **Cấu trúc cú pháp (10%):** mức độ tương đồng về cách tổ chức câu, quan hệ giữa các thành phần.
- **Ngữ cảnh sử dụng (10%):** mức độ phù hợp của câu diễn giải với cùng bối cảnh sử dụng của câu gốc

Mỗi tiêu chí được chấm theo thang điểm từ 0 đến 4. Dựa trên các ví dụ trên, ta có thể đánh giá mức độ tương đồng của các câu diễn giải so với câu gốc theo thang điểm:

- **0 – Không tương đồng:** Câu diễn giải hoàn toàn sai lệch với ý nghĩa của câu gốc.
- **1 – Rất ít tương đồng:** Câu diễn giải có liên quan một phần nhưng vẫn bị sai về ngữ nghĩa hoặc ngữ cảnh.
- **2 – Trung bình:** Câu diễn giải thể hiện đúng một phần ý nghĩa nhưng thiếu đi một số chi tiết quan trọng.

- **3 – Khá tương đồng:** Câu diễn giải gần như đầy đủ ý nghĩa của câu gốc nhưng có thể mất đi một chút sắc thái.
- **4 – Rất tương đồng:** Câu diễn giải truyền tải trọn vẹn ý nghĩa, sắc thái và phù hợp với ngữ cảnh của câu gốc.

Ví dụ:

Câu gốc: *"Anh ta là bức tường phòng thủ vững chắc của đội bóng."*

Kết quả: Bảng 3.5.

Bảng 3.5: Ví dụ thang điểm độ tương đồng ngữ nghĩa giữa câu gốc và câu diễn giải

Tiêu chí	0	1	2	3	4
Tương đồng về nghĩa mệnh đề	*"Anh ta là một thợ xây dựng giỏi, chuyên làm tường."*	*"Anh ta là một cầu thủ khỏe mạnh."*	*"Anh ta là một hậu vệ giỏi trong đội bóng."*	*"Anh ta là một hậu vệ kiên cường, rất khó bị vượt qua."*	*"Anh ta là một bức tường phòng thủ thực sự, luôn bảo vệ khung thành một cách vững chắc."*
Tương đồng về nghĩa tình thái	*"Anh ta làm việc chăm chỉ mỗi ngày."*	*"Anh ta chơi bóng rất nỗ lực."*	*"Anh ta là một cầu thủ có trách nhiệm và luôn tập trung."*	*"Anh ta là một cầu thủ mạnh mẽ và đáng tin cậy trong phòng ngự."*	*"Anh ta là chốt chặn vững chắc nhất của đội, không ai có thể vượt qua anh ta một cách dễ*

					dàng."
Tương đồng về hàm ý	*"Anh ta là một người rất giỏi xây nhà."*	*"Anh ta là người có thể giúp đồng đội yên tâm."*	*"Anh ta là một cầu thủ có khả năng phòng ngự tốt."*	*"Anh ta là một người cản phá xuất sắc, luôn khiến đối phương gặp khó khăn."*	*"Anh ta là một hậu vệ thép, luôn chặn đứng mọi đợt tấn công của đối thủ."*
Tương đồng về cấu trúc cú pháp	*"Anh ta đứng trước một bức tường lớn."*	*"Anh ta là một cầu thủ quan trọng trong đội bóng."*	*"Anh ta là trụ cột phòng ngự của đội bóng."*	*"Anh ta là lá chắn kiên cố trong hàng phòng ngự của đội."*	*"Anh ta là bức tường phòng thủ kiên cố, không ai có thể xuyên thủng."*
Tương đồng về ngữ cảnh sử dụng	*"Trong kiến trúc, tường là phần quan trọng của ngôi nhà."*	*"Trong thể thao, có nhiều cầu thủ xuất sắc."*	*"Trong bóng đá, hậu vệ đóng vai trò bảo vệ khung thành."*	*"Trong bóng đá, một hậu vệ giỏi phải biết cản phá tốt."*	*"Trong bóng đá, thuật ngữ 'bức tường phòng thủ' thường dùng để chỉ một hậu vệ cực kỳ chắc chắn."*

3.3.3. Quy trình gán nhãn dữ liệu

Quy trình gán nhãn trong nghiên cứu này được thiết kế theo mô hình kết hợp người–máy (human-in-the-loop), trong đó mô hình ngôn ngữ lớn (LLM) đóng vai trò hỗ trợ gợi ý ban đầu, còn quyết định cuối cùng thuộc về annotators con người. Cách tiếp cận này giúp giảm tải công việc thủ công, đồng thời vẫn đảm bảo tính chính xác và độ tin cậy của dữ liệu gán nhãn. Quy trình bao gồm năm bước chính, được mô tả chi tiết như sau:

Bước 1. Tiền xử lý bằng LLM (gợi ý tự động)

Toàn bộ dữ liệu đầu vào được đưa qua mô hình Vistral-7B-Chat để thực hiện bước tiền xử lý. Ở giai đoạn này, mô hình đảm nhiệm hai nhiệm vụ chính: (i) phát hiện ẩn dụ ở cấp độ span, tức là xác định các từ hoặc cụm từ có khả năng mang tính ẩn dụ trong câu; và (ii) đề xuất loại ẩn dụ tương ứng theo hệ thống phân loại gồm năm nhóm: ẩn dụ cấu trúc, ẩn dụ định hướng, ẩn dụ bản thể, ẩn dụ cảm xúc và ẩn dụ văn hóa dân gian.

Các kết quả do mô hình sinh ra chỉ mang tính gợi ý ban đầu, nhằm hỗ trợ annotators trong các bước tiếp theo, và không được xem là nhãn cuối cùng. Mục tiêu của bước này là tăng hiệu quả làm việc và giúp annotators tập trung vào việc kiểm tra, hiệu chỉnh và diễn giải chuyên sâu.

Bước 2. Annotator 1 – Gán nhãn và diễn giải

Annotator 1 tiếp nhận dữ liệu cùng các gợi ý từ LLM và thực hiện hai tác vụ cốt lõi: diễn giải ẩn dụ và phân loại ẩn dụ.

Đối với tác vụ diễn giải ẩn dụ (Metaphor Interpretation), annotator viết lại câu gốc bằng cách thay thế các biểu đạt ẩn dụ bằng cách diễn đạt tường minh hơn, sao cho người đọc phổ thông có thể dễ dàng hiểu được nội dung. Quá trình diễn giải phải đảm bảo giữ nguyên nội dung mệnh đề và sắc thái biểu cảm của câu gốc. Trong trường hợp câu chứa nhiều tầng ngữ nghĩa hoặc ẩn dụ phức tạp, annotator được phép diễn giải riêng cho từng span (từng từ hoặc cụm từ mang tính ẩn dụ), sau đó ghép lại thành một diễn giải tổng thể. Cách làm này giúp làm rõ từng lớp nghĩa và hạn chế việc bỏ sót hoặc làm mờ các yếu tố ẩn dụ quan trọng.

Song song với diễn giải, annotator thực hiện phân loại ẩn dụ (Metaphor Classification) bằng cách kiểm tra, xác nhận hoặc chỉnh sửa các nhãn do LLM đề xuất. Việc phân loại được thực hiện dựa trên guideline đã thống nhất, và trong trường hợp một câu mang nhiều lớp ẩn dụ, annotator có thể gán nhiều nhãn đồng thời.

Bước 3. Annotator 2 – Đánh giá và phản biện

Sau khi Annotator 1 hoàn tất công đoạn gán nhãn, kết quả được chuyển sang Annotator 2 để thực hiện đánh giá độc lập. Ở bước này, Annotator 2 đóng vai trò kiểm soát chất lượng và phản biện.

Trước hết, Annotator 2 đánh giá câu diễn giải theo ba tiêu chí chất lượng, bao gồm: độ chính xác (mức độ giữ đúng nghĩa gốc và tương đương ngữ nghĩa), độ rõ ràng (mức độ dễ hiểu, không gây nhiễu nghĩa) và độ tự nhiên (mức độ trôi chảy, phù hợp với văn phong tiếng Việt). Các tiêu chí này được chấm điểm theo thang đo đã định nghĩa trong guideline.

Bên cạnh đó, Annotator 2 thực hiện Paraphrase Judgement, tức là đánh giá chất lượng diễn giải của câu diễn giải so với câu gốc. Trong trường hợp diễn giải

được thực hiện theo từng span, annotator cần đánh giá không chỉ tính chính xác của từng diễn giải cục bộ mà còn tính liên kết và nhất quán khi ghép lại thành câu hoàn chỉnh. Ngoài ra, Annotator 2 có thể chấm thêm mức độ tương đồng ngữ nghĩa theo năm khía cạnh: nghĩa mệnh đề, nghĩa tình thái, cấu trúc cú pháp, hàm ý và ngữ cảnh sử dụng.

Bước 4. Xử lý bất đồng và thống nhất nhãn

Trong trường hợp Annotator 2 không đồng ý với kết quả của Annotator 1, annotator thứ hai sẽ ghi chú rõ lý do phản biện trực tiếp trong công cụ gán nhãn. Những trường hợp có mức độ bất đồng cao hoặc khó phân định được chuyển sang thảo luận nhóm, với sự tham gia của các annotators và người phụ trách chuyên môn. Sau mỗi vòng thảo luận, guideline được cập nhật và tinh chỉnh nhằm làm rõ các tiêu chí còn mơ hồ, từ đó nâng cao tính nhất quán trong các vòng gán nhãn tiếp theo. Cơ chế này giúp guideline không mang tính tĩnh mà được cải tiến liên tục dựa trên thực tiễn annotate.

Bước 5. Lưu trữ và tổ chức dữ liệu

Khi một mẫu dữ liệu đã hoàn tất toàn bộ các bước gán nhãn và đánh giá, hệ thống sẽ tự động lưu trữ thông tin theo cấu trúc dữ liệu chuẩn hóa, phục vụ cho cả huấn luyện mô hình và phân tích định lượng.

3.3.4. Kết quả độ đồng thuận

Từ tập dữ liệu ban đầu, nhóm trích ra tập Groundtruth gồm **1.000 mẫu**, sử dụng LLM để gợi ý nhãn, sau đó tổ chức huấn luyện annotator theo từng vòng với **100 mẫu mỗi vòng**. Hai annotator độc lập thực hiện gán nhãn, kết quả được đánh giá mức độ nhất quán liên chủ thể (inter-annotator agreement) thông qua các chỉ số: Token F1 và % exact cho span, Cohen's Kappa cho type, và cosine similarity cho

diễn giải. Nếu mức độ đồng thuận đạt ngưỡng ≥ **0,85**, guideline được chốt và tiến hành annotate trên diện rộng; ngược lại, guideline được cập nhật và quy trình tiếp tục lặp lại cho đến khi đạt yêu cầu.

Hình 3.3 cho thấy xu hướng **tăng ổn định** về mức độ đồng thuận ở cả bốn tác vụ: Metaphor Identification, Span Identification, Metaphor Classification và Metaphor Interpretation khi số vòng annotate tăng lên. Điều này phản ánh rõ hiệu quả của cơ chế học tập dần (learning effect) của annotators, cũng như vai trò tích cực của việc cập nhật và tinh chỉnh guideline sau mỗi vòng.

Ở tác vụ Metaphor Identification, độ đồng thuận luôn **duy trì ở mức cao ngay từ đầu (xấp xỉ 0.82 ở vòng 1) và tăng dần lên gần 0.95 ở vòng 10**. Đây là kết quả dễ lý giải, bởi việc nhận diện sự tồn tại của ẩn dụ ở cấp câu tương đối trực quan hơn so với các tác vụ sâu hơn về ngữ nghĩa. Mức tăng nhẹ nhưng đều cho thấy guideline về nhận diện ẩn dụ ngày càng rõ ràng và ổn định.

Đối với Span Identification, độ đồng thuận ban đầu thấp hơn Metaphor Identification và có **dao động nhẹ trong các vòng đầu** (đặc biệt ở vòng 2–3). Điều này phản ánh độ khó vốn có của việc xác định chính xác ranh giới từ/cụm từ mang tính ẩn dụ. Tuy nhiên, từ vòng 6 trở đi, chỉ số này tăng rõ rệt và đạt trên 0.9 ở vòng cuối, cho thấy annotators đã dần thống nhất cách xử lý các trường hợp biên và cấu trúc ẩn dụ phức tạp.

Tác vụ Metaphor Classification thể hiện **mức độ đồng thuận tương đối cao và ổn định**, tăng đều từ khoảng 0.80 lên trên 0.9. Xu hướng này cho thấy hệ thống phân loại 5 loại ẩn dụ được xây dựng là khả thi và dễ áp dụng trong thực tế, đồng thời các ví dụ và quy tắc trong guideline đã giúp giảm đáng kể sự khác biệt trong cách hiểu giữa các annotators.

Ngược lại, Metaphor Interpretation là tác vụ có **độ đồng thuận thấp nhất ở giai đoạn đầu** (khoảng 0.6), phản ánh đúng tính chất chủ quan và phức tạp của việc diễn giải ẩn dụ. Tuy nhiên, đây cũng là tác vụ có mức cải thiện tương đối lớn nhất, tăng đều qua các vòng và đạt khoảng 0.85 ở vòng 10. Kết quả này cho thấy việc áp dụng các tiêu chí đánh giá cụ thể (chính xác, rõ ràng, tự nhiên) cùng cơ chế phản biện và thảo luận đã giúp thu hẹp đáng kể khác biệt trong cách diễn giải giữa hai annotator.

Tổng thể, biểu đồ cho thấy quy trình gán nhãn được thiết kế có tính hiệu quả cao, với độ đồng thuận tăng dần và hội tụ theo thời gian ở tất cả các tác vụ. Điều này không chỉ khẳng định độ tin cậy của Ground truth set, mà còn chứng minh rằng guideline và cơ chế xử lý bất đồng đã phát huy tốt vai trò trong việc chuẩn hóa hành vi gán nhãn, đặc biệt đối với các tác vụ mang tính ngữ nghĩa sâu như diễn giải ẩn dụ

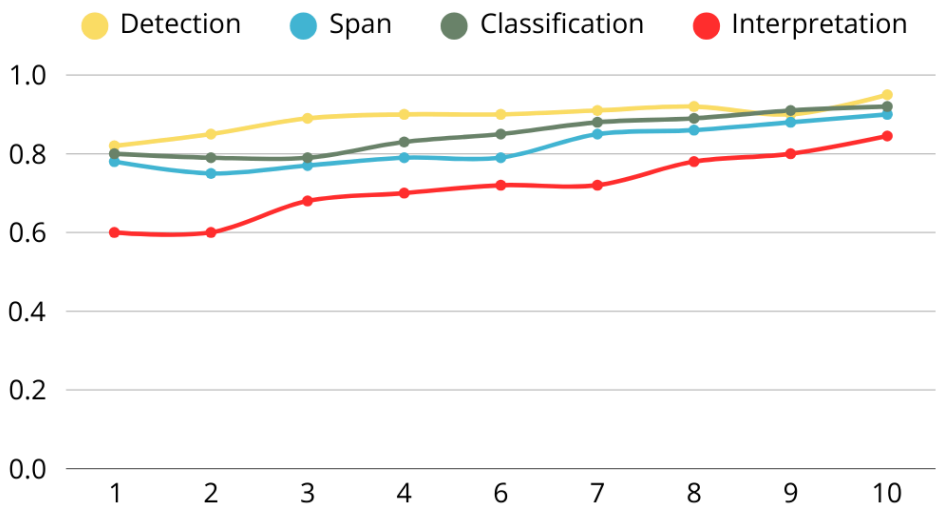

Hình 3.3: Mức độ đồng thuận giữa các annotator (Inter-annotator Agreement)

Hình 3.4 cho thấy **intra-annotator agreement của cả hai annotator đều ở mức rất cao trên hầu hết các tác vụ**. Cụ thể, các bước Metaphor Identification và Span Identification đạt giá trị xấp xỉ tuyệt đối (≈1.0), trong khi Metaphor Classification duy trì mức ổn định cao (khoảng 0.97–0.99). Ngược lại, Metaphor Interpretation có giá trị thấp hơn tương đối (khoảng 0.92–0.94), phản ánh tính chủ quan cao hơn của bước diễn giải so với các tác vụ còn lại. Nhìn chung, kết quả cho thấy quy trình và guideline gán nhãn đủ rõ ràng, giúp đảm bảo tính nhất quán nội tại tốt cho cả hai annotator.

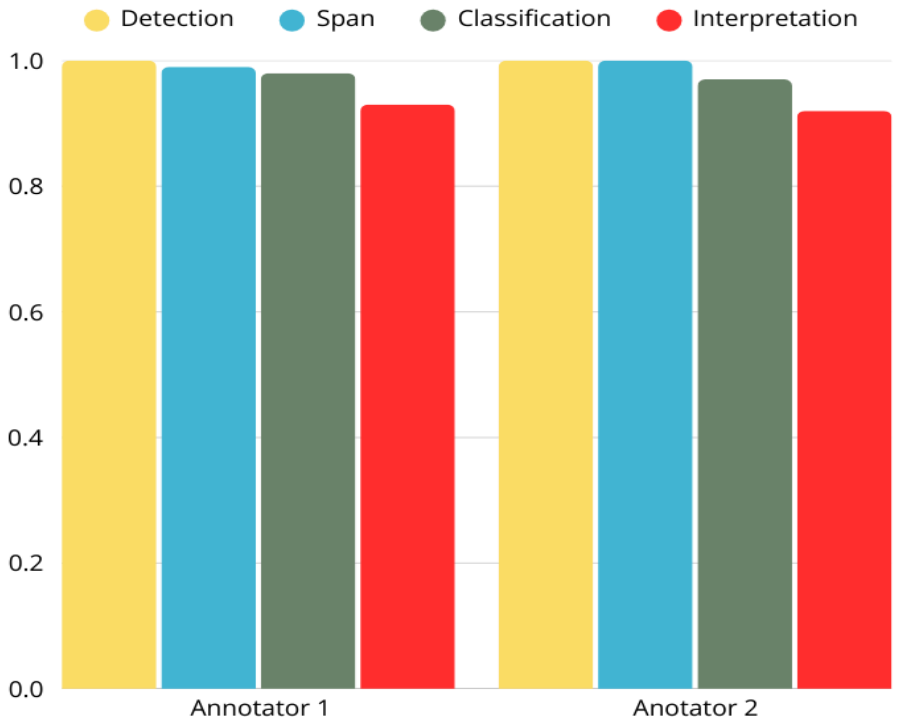

Hình 3.4: Mức độ nhất quán trong gán nhãn của từng annotator (Intra-annotator Agreement)

3.4. Phân tích dữ liệu

3.4.1 Mô tả dữ liệu

Sau khi hoàn tất các bước thu thập, tiền xử lý dữ liệu và quy trình gán nhãn, nhóm thu được bộ dữ liệu với 8501 mẫu bao gồm tất cả 23 thuộc tính được chia thành các nhóm như sau:

A) Nhóm thuộc tính chính:

Bảng 3.6: Nhóm các thuộc tính chính mô tả dữ liệu gán nhãn

Trường dữ liệu	Mô tả
id	Mã định danh cho mỗi mẫu
sentence	Câu thơ hoặc câu văn ban đầu chứa ẩn dụ
have_metaphor	Xác định sentence có ẩn dụ hay không
metaphor_phrases	Danh sách các span/cụm ẩn dụ (kèm vị trí)
interpretation	Câu diễn giải nghĩa (Annotators thực hiện)

metaphor_types	Nhãn phân loại ẩn dụ (Annotators gán)
scores	Cụm điểm đánh giá gốc
notes	Ghi chú bổ sung trong quá trình gán nhãn

B) Nhóm các thuộc tính trích dẫn để thống kê/kiểm soát dữ liệu:

Bảng 3.7: Nhóm các thuộc tính trích dẫn phục vụ thống kê và kiểm soát chất lượng dữ liệu

Trường dữ liệu	**Mô tả**
num_metaphor_types	Số loại ẩn dụ được gán trong mẫu
num_metaphor_phrases	Số span/cụm ẩn dụ trong mẫu
has_interpretation	Cờ cho biết có/không có diễn giải
has_scores	Cờ cho biết có/không có điểm đánh giá

sentence_len	Độ dài câu

C) Nhóm điểm thành phần:

Bảng 3.8: Các điểm thành phần dùng trong đánh giá diễn giải ẩn dụ

Trường dữ liệu	Mô tả
score_accuracy	Độ đúng so với ý nghĩa gốc
score_clarity	Độ rõ ràng/dễ hiểu của diễn giải
score_naturalness	Độ tự nhiên/thuần Việt của diễn giải
score_meaning	Tương đồng về nội dung/nghĩa
score_modality	Tương đồng về sắc thái/tình thái
score_implication	Tương đồng về hàm ý/ngụ ý
score_syntax	Tương đồng về cấu trúc/cú pháp
score_context	Tương đồng theo ngữ cảnh

D) Nhóm điểm tổng hợp:

Bảng 3.9: Các điểm tổng hợp phản ánh chất lượng diễn giải và mức độ tương đồng ngữ nghĩa

Trường dữ liệu	Mô tả
score_quality	Điểm tổng hợp từ các điểm thành phần tương ứng theo công thức
score_overall	

3.4.2 Phân bố dữ liệu.

Trong số 8501 mẫu của bộ dữ liệu, **nhóm câu không có ẩn dụ chiếm 5319 câu (62,6%), còn lại 3182 câu có chứa ẩn dụ (37,4%)**. Phân bố này phản ánh thực tế rằng trong các văn bản, văn nói tự nhiên, **những câu chứa ẩn dụ xuất hiện không nhiều** (hình 3.5).

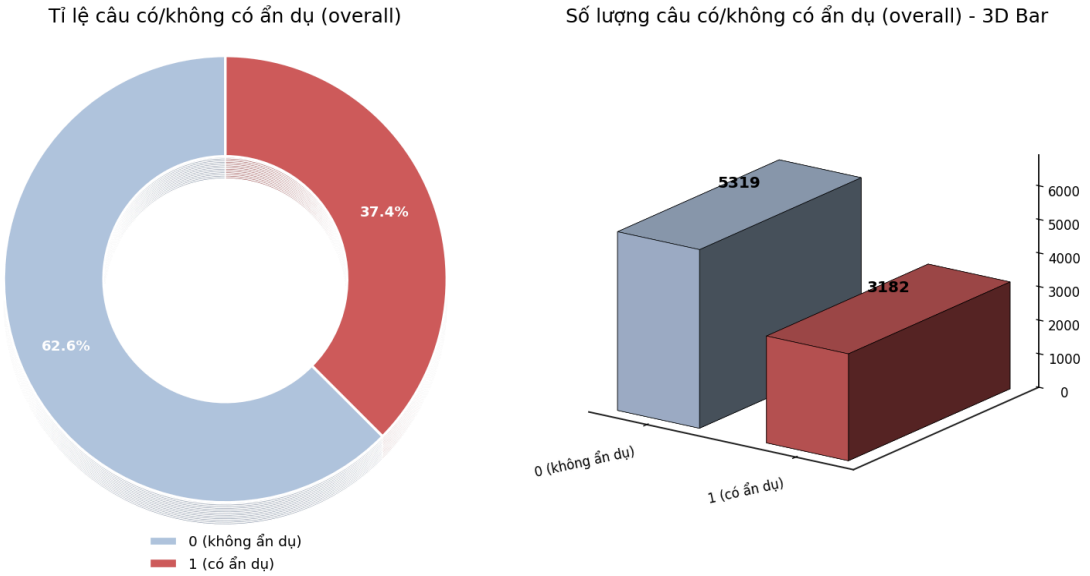

Hình 3.5: Phân bố các loại ẩn dụ trong bộ dữ liệu ViMUNCH

Để đánh giá đặc điểm phân bố độ dài câu và kiểm tra khả năng tồn tại mối liên hệ giữa độ dài với các câu có chứa ẩn dụ, nhóm đã thống kê tỉ lệ mẫu theo các khoảng độ dài (0–30, 31–60, 61–100, 101–200 và >200) và so sánh riêng cho hai lớp have_metaphor = 0 và have_metaphor = 1. Kết quả cho thấy **cả hai lớp đều tập trung chủ yếu ở nhóm câu có độ dài trung bình 31–100**, tuy nhiên **phân bố giữa hai lớp không hoàn toàn đồng nhất**: lớp không ẩn dụ xuất hiện nhiều hơn ở các câu ngắn (đặc biệt 0–30), trong khi lớp có ẩn dụ có xu hướng tăng tỉ lệ ở các câu dài, rõ nhất từ mốc 101–200 và vẫn duy trì một phần ở nhóm >200. Điều này cho thấy rằng độ dài câu có tương quan với khả năng xuất hiện ẩn dụ - trong thơ, văn,

câu càng dài thì càng có xu hướng chứa ẩn dụ, do có nhiều thông tin biểu đạt và liên tưởng nhiều hơn (hình 3.6).

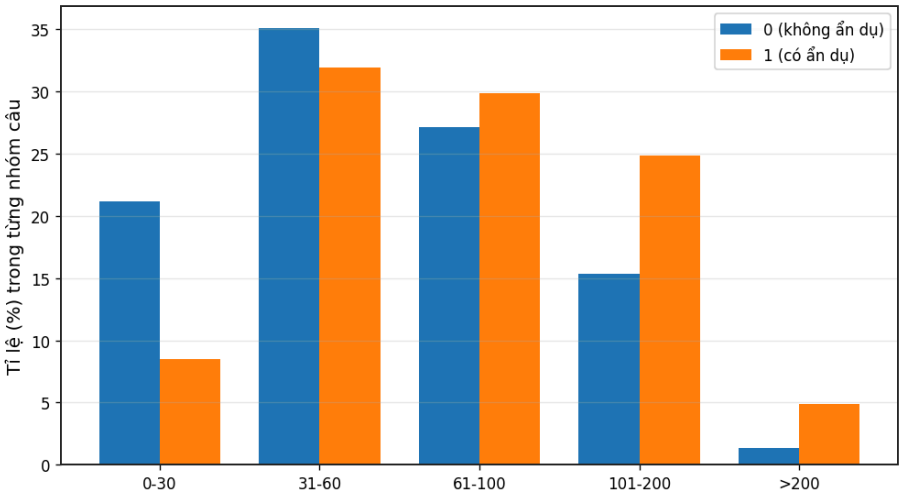

Hình 3.6: Phân bố độ dài câu trong bộ dữ liệu ViMUNCH

Tiếp theo, để hiểu rõ thành phần các loại ẩn dụ trong bộ dữ liệu (tức dữ liệu đang nghiêng về kiểu ẩn dụ nào nhiều hơn), nhóm tiến hành thống kê trường metaphor_types và biểu diễn cả tỉ lệ lẫn số lượng theo từng nhãn. Kết quả cho thấy **hai nhóm chiếm tỉ trọng lớn nhất là emotional (1.730 mẫu, 35,2%) và ontological (1.558 mẫu, 31,7%)**, sau đó là structural (932 mẫu, 19,0%). Các nhóm còn lại xuất hiện ít hơn gồm cultural_folklore (381 mẫu, 7,8%), orientational (288 mẫu, 5,9%) và other (23 mẫu, 0,5%). Như vậy, **phân bố nhãn có xu hướng lệch về một vài nhóm phổ biến, trong khi các nhãn hiếm có rất ít mẫu** (hình 3.7).

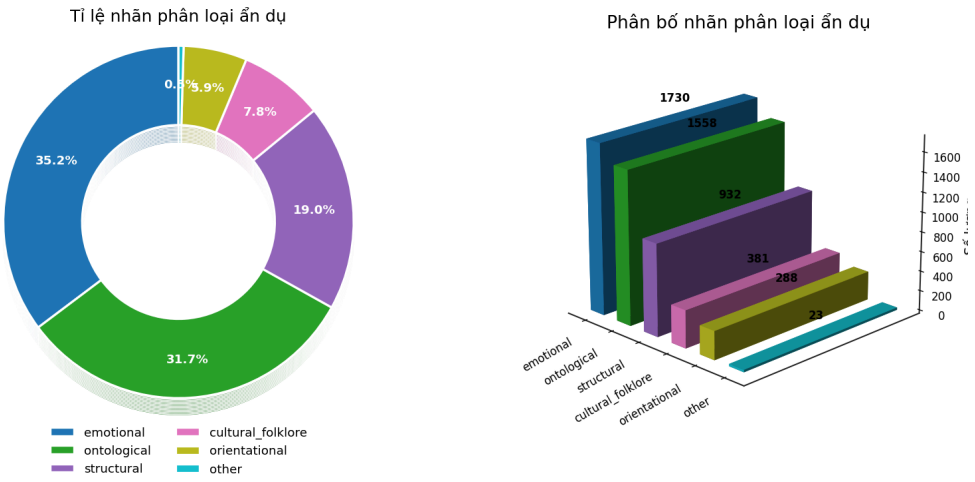

Hình 3.7: Phân bố số lượng và tỷ lệ các loại ẩn dụ

Sự phân bố thể loại trong tập dữ liệu nền đóng vai trò tiên quyết trong việc xác lập ngữ cảnh cho các phân tích ngôn ngữ học chuyên sâu. Theo quan sát từ Hình 3.8, số lượng bài viết giữa thơ và văn xuôi trước tiền xử lý đạt được trạng thái cân bằng tương đối, tạo điều kiện thuận lợi cho việc so sánh các đặc trưng tu từ giữa hai loại hình văn bản này. Tỉ lệ câu chứa ẩn dụ trong tập dữ liệu sau tiền xử lý chiếm khoảng 37%, trong đó sự chênh lệch mật độ giữa thơ và văn xuôi vẫn được duy trì một cách nhất quán so với tập dữ liệu gốc. Điều này cho thấy sự chênh lệch đáng kể giữa hai thể loại về số lượng câu ở mỗi bài viết.

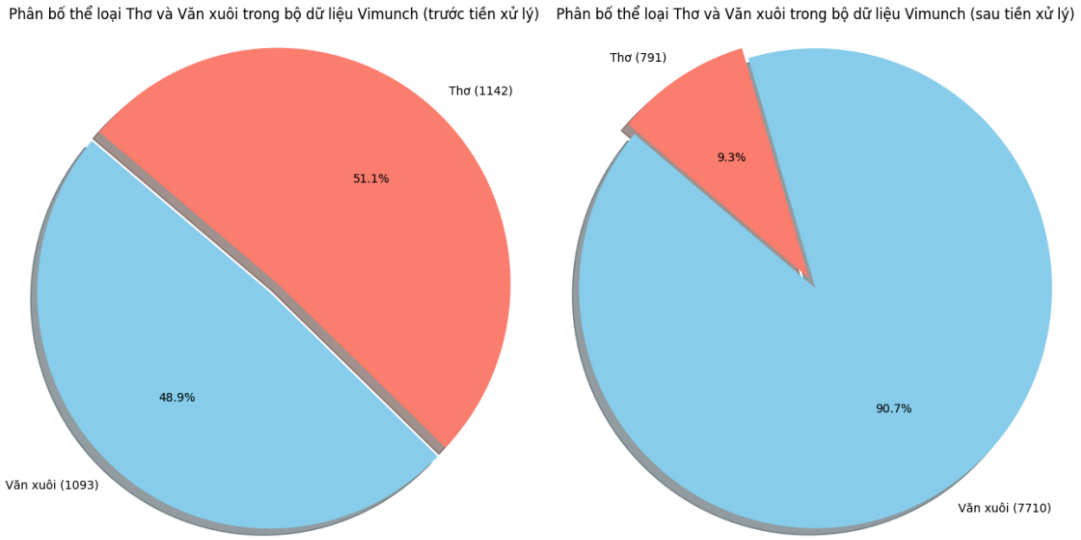

Hình 3.8: Phân bố thể loại Thơ và Văn xuôi

Phân tích mật độ ẩn dụ tại Hình 3.9 cho thấy một sự chênh lệch rõ rệt về tần suất xuất hiện của các biện pháp tu từ giữa các thể loại văn học. Trong khi văn xuôi duy trì một tỉ lệ ẩn dụ vừa phải nhằm phục vụ mục đích dẫn dắt tình tiết và mô tả thực tế, thì thơ ca lại khẳng định vai trò là môi trường giàu ẩn dụ nhất với mật độ vượt trội. Đặc điểm này hoàn toàn phù hợp với lý thuyết ngôn ngữ học tri nhận, khi thơ ca thường sử dụng các miền nguồn cụ thể để diễn tả những miền đích trừu tượng về tâm trạng và tư tưởng.

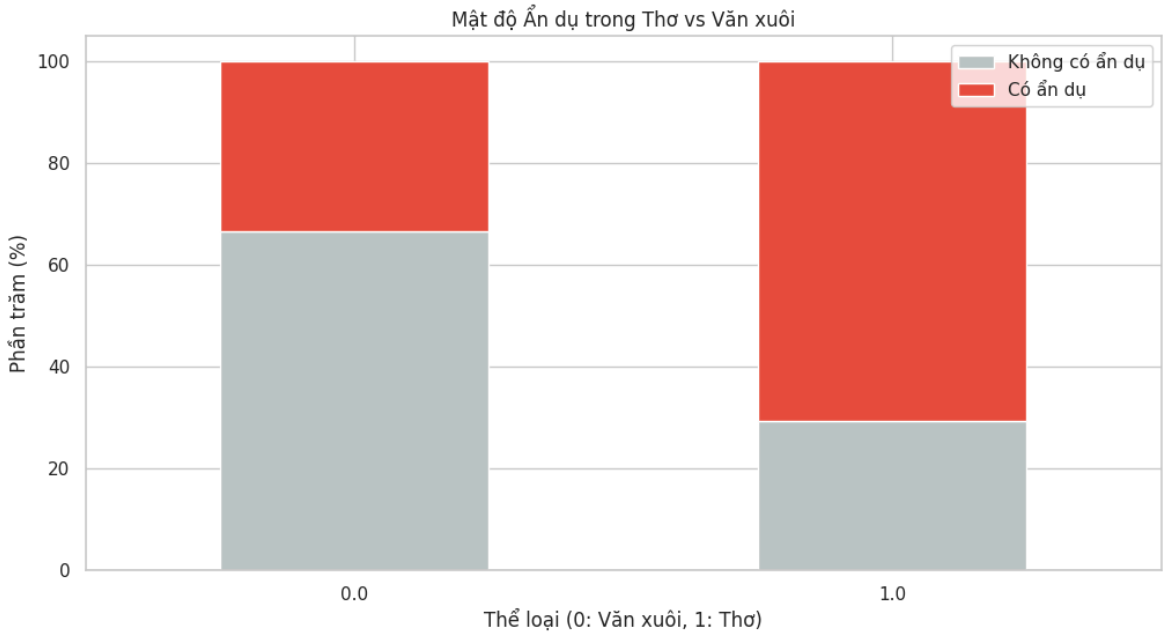

Hình 3.9: Thống kê tỉ lệ ẩn dụ theo thể loại (%)

Hình 3.10 cung cấp cái nhìn sâu sắc về tính sáng tạo trong tập dữ liệu. Các cụm từ xuất hiện với tần suất cao như "nắng", "gió", "thời gian" hay "cuộc đời" minh chứng cho sự tồn tại của các ẩn dụ hệ thống trong tư duy người Việt, nơi thiên nhiên và các khái niệm trừu tượng thường được nhân hóa để biểu đạt trạng thái nhân sinh.

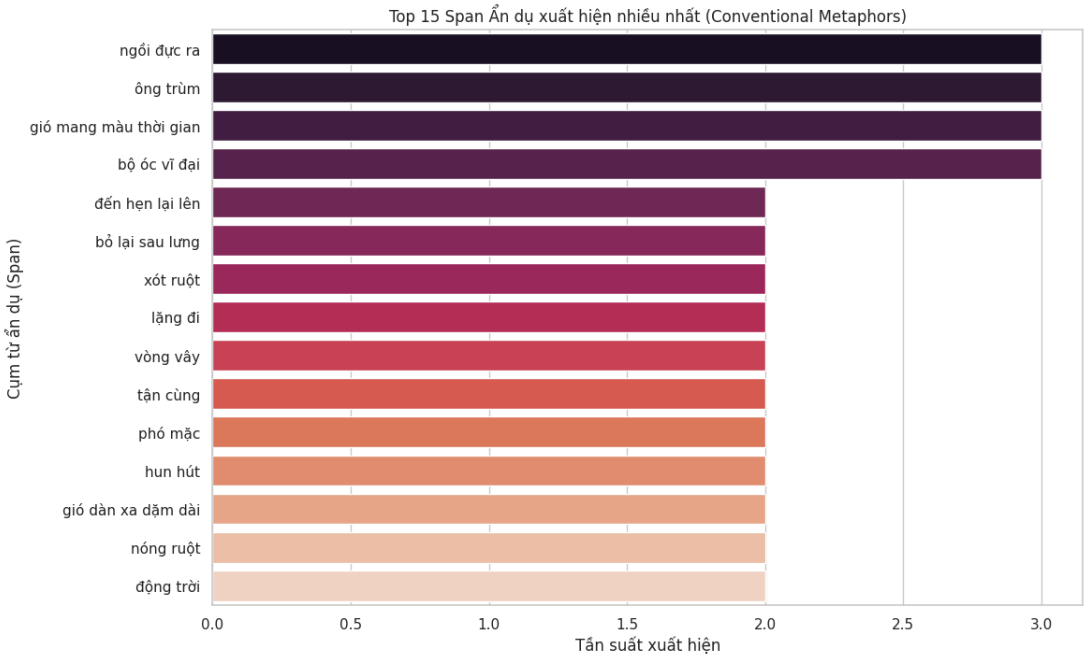

Hình 3.10: Top 15 từ/cụm từ ẩn dụ xuất hiện nhiều nhất

Ma trận tương quan giữa các tiêu chí đánh giá tại Hình 3.11 phản ánh một đặc trưng quan trọng trong việc diễn giải ẩn dụ văn chương: sự tách biệt rõ rệt giữa tính minh bạch bề mặt và độ sâu ngữ nghĩa. Kết quả phân tích cho thấy hệ số tương quan giữa độ chính xác và độ rõ ràng đạt mức rất thấp (xấp xỉ 0,20), minh chứng cho một nghịch lý trong diễn giải nghệ thuật khi một câu văn diễn giải có cấu trúc đơn giản, dễ hiểu chưa chắc đã truyền tải đúng và đủ các tầng nghĩa ý niệm phức tạp của nguyên tác. Trong khi đó, mối liên hệ mật thiết giữa độ chính xác và chất lượng tổng thể (xấp xỉ 0,98) khẳng định rằng giá trị của một bản diễn giải ẩn dụ được định đoạt chủ yếu bởi khả năng bảo toàn đúng cơ chế ánh xạ khái niệm hơn là việc chỉ đơn thuần phẳng hóa ngôn từ cho mục đích thông tin. Sự thiếu tương quan này không chỉ bảo đảm tính độc lập của các chiều đo lường trong bộ dữ liệu mà còn đặt ra thách thức cho các mô hình ngôn ngữ lớn trong việc vượt qua sự trôi chảy hình thức để chạm đến bản chất tư duy hình tượng, đặc biệt đối với các ẩn dụ sáng

tạo độc bản vốn thường đòi hỏi sự đánh đổi giữa tính chính xác khoa học và tính tinh giản của ngôn ngữ giao thông thường.

Hình 3.11: Ma trận tương quan giữa các tiêu chí đánh giá diễn giải

Việc phân tích các mẫu dữ liệu bất thường và các phân đoạn ẩn dụ tại Bảng 3.10 cho thấy tính đa dạng và phức tạp của ngôn ngữ văn chương. Sự hiện diện của các ẩn dụ toàn thể, nơi mà ý nghĩa ẩn dụ không nằm ở một cụm từ duy nhất mà bao trùm lên toàn bộ cấu trúc câu, đã tạo ra các phân đoạn rỗng trong dữ liệu gán nhãn. Đồng thời, những mẫu dữ liệu có độ dài vượt ngưỡng hoặc điểm đánh giá thấp cũng

phản ánh những rào cản kỹ thuật trong việc tách câu và diễn giải các khái niệm quá trừu tượng. Việc lý giải các điểm bất thường này không chỉ giúp hoàn thiện bộ dữ liệu mà còn đóng góp vào việc nhận diện các giới hạn của mô hình máy tính khi tiếp cận với các văn bản mang tính sáng tạo độc bản và đa trị của Báo Văn Nghệ.

Bảng 3.10: Thống kê những đặc điểm bất thường

Các đặc điểm bất thường phổ biến	**Số lượng mẫu bất thường**	**Ví dụ**
Sự thiếu nhất quán về logic (Ẩn dụ trừu tượng/thiếu ngữ cảnh)	50	"Nghe giọt đắng thấm vào hồn ngày cũ", "Biết đâu mùa tóc trắng vẽ ngày xanh"
Bất thường về cấu trúc (Câu có độ dài vượt mức 80 t)	37	Trích đoạn bài thơ "Gió Ngàn" dài 117 từ, bao gồm nhiều câu thơ gộp lại không có dấu ngắt.
Bất thường về kết quả đánh giá (Điểm chất lượng cực thấp)	14	Câu gốc: "HÁT VĂN Đốt tiếng Việt" Diễn giải: "HÁT VĂN làm hủy hoại hoặc làm biến dạng tiếng Việt"

Các đặc điểm bất thường phổ biến	Số lượng mẫu bất thường	Ví dụ
		• Điểm tổng chất lượng diễn giải: 1.20

3.4.3 Chia dữ liệu

Trong bước chia tập dữ liệu, mục tiêu của nhóm là tạo ra ba tập train/dev/test có tính đại diện và đồng nhất về phân bố, để kết quả huấn luyện và đánh giá không bị "lệch" do cách chia mẫu. Vì vậy, nhóm thực hiện chia dữ liệu theo hướng giữ ổn định phân bố nhãn (stratify theo have_metaphor) và sau đó kiểm tra lại các đặc trưng quan trọng bằng ba biểu đồ: tỉ lệ câu có ẩn dụ, phân bố độ dài câu và phân bố loại ẩn dụ.

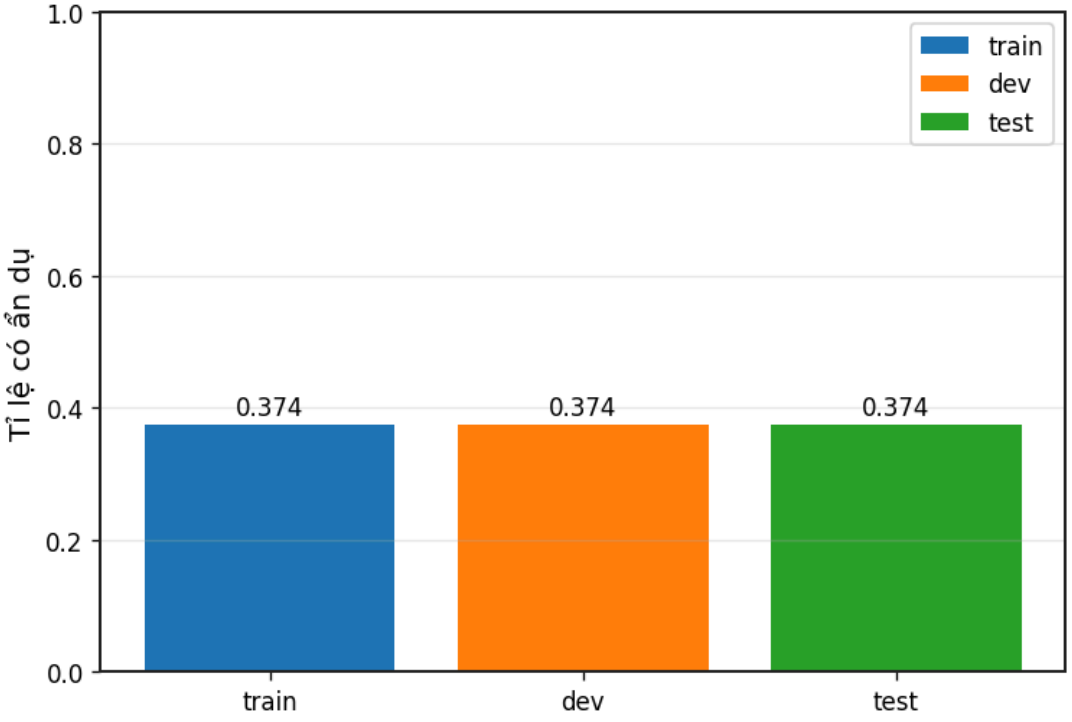

Hình 3.12: So sánh tỷ lệ câu chứa ẩn dụ giữa các tập train/dev/test

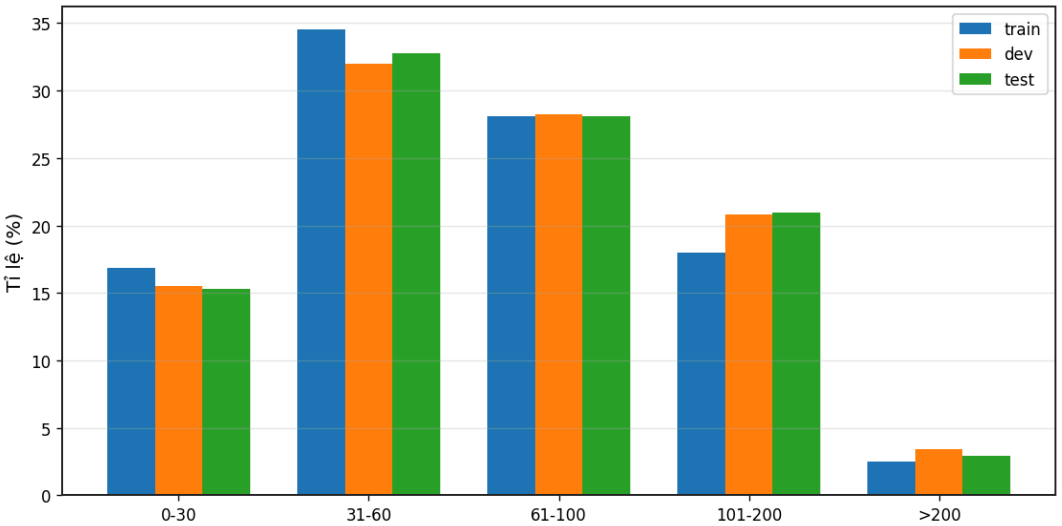

Hình 3.13: So sánh phân bố độ dài câu giữa các tập train/dev/test

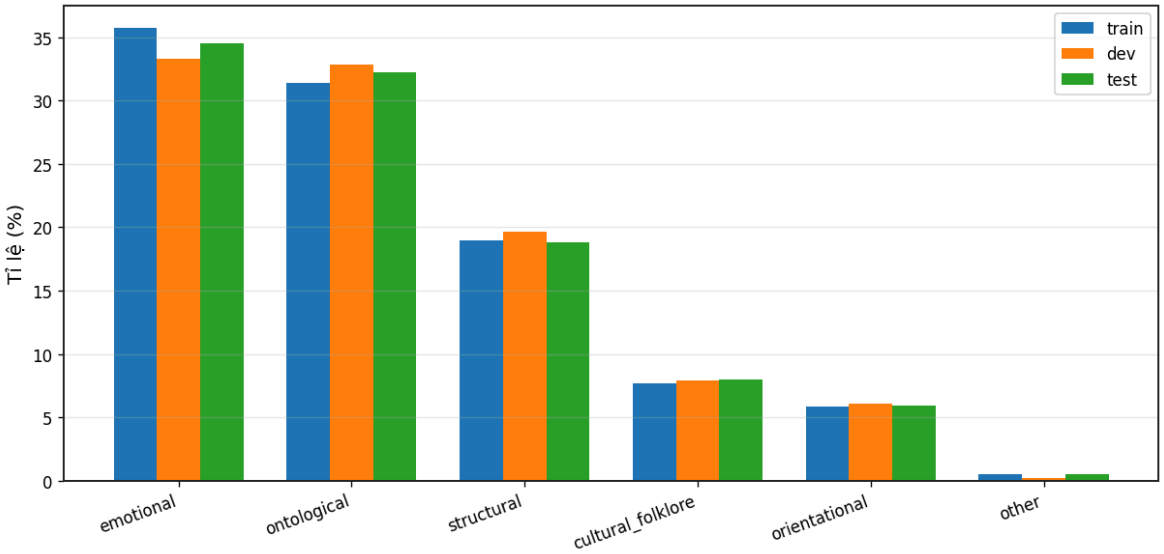

Hình 3.14: So sánh phân bố các loại ẩn dụ giữa các tập train/dev/test

Kết quả kiểm tra cho thấy **việc chia tập là phù hợp**. Thứ nhất, tỉ lệ câu có ẩn dụ sau khi chia là gần như giống nhau giữa train/dev/test (đều khoảng 0,374), đảm bảo độ cân bằng nhãn nhất quán và giúp việc so sánh mô hình công bằng. Thứ hai, phân bố độ dài câu theo các khoảng (0–30, 31–60, 61–100, 101–200, >200) giữa ba tập nhìn chung tương đồng, không xuất hiện hiện tượng một tập bị "thiên" về câu quá ngắn hoặc quá dài. Thứ ba, phân bố các loại ẩn dụ cũng được giữ ổn định giữa các split: các nhãn phổ biến như emotional và ontological vẫn chiếm tỉ trọng lớn nhất, structural đứng tiếp theo, trong khi các nhãn hiếm (other) duy trì tỉ lệ rất nhỏ ở cả ba tập. (Hình 3.11, 3.12, 3.13).

CHƯƠNG 4: THỬ NGHIỆM VÀ KẾT QUẢ

Chương này trình bày thiết lập thử nghiệm và kết quả đánh giá cho bài toán hiểu ẩn dụ tiếng Việt theo hướng đa nhiệm (multitask). Trên cơ sở bộ dữ liệu đã được mô tả và phân tích ở Chương 3, nhóm tiến hành so sánh nhiều mô hình ngôn ngữ lớn trong ba cấu hình triển khai: zero-shot, few-shot (5 ví dụ), fine-tuning. Các thí nghiệm được thiết kế nhằm trả lời hai câu hỏi chính: (i) năng lực gốc của các LLM trong việc nhận diện–phân loại–diễn giải ẩn dụ tiếng Việt đến đâu, và (ii) mức cải thiện khi bổ sung ngữ cảnh ví dụ (few-shot) hoặc thích nghi tham số theo dữ liệu miền (fine-tuning). Kết quả được báo cáo theo từng nhiệm vụ, đồng thời đi kèm phân tích tác động của từng hướng tiếp cận và các dạng lỗi điển hình.

4.1 Tổng quát thử nghiệm

4.1.1. Các nhiệm vụ đánh giá (multitask)

Nhóm yêu cầu các mô hình thực hiện chuỗi nhiệm vụ sau:

Task 1 (Metaphor Identification + Span Extraction): Dự đoán câu có ẩn dụ hay không. Nếu câu có ẩn dụ, trích xuất span (đoạn văn bản) chứa ẩn dụ.

Task 2 (Metaphor classification): Phân loại loại ẩn dụ theo hệ nhãn của bộ dữ liệu (đa nhãn – một câu có thể thuộc nhiều loại).

Task 3 (Metaphor Interpretation): Diễn giải ẩn dụ, viết lại nội dung câu theo nghĩa tường minh. Không thêm, bớt ý.

Task 4 (Paraphrase Judgement): Mô hình đóng vai "giám khảo" chấm điểm câu diễn giải của annotators trong gold data theo rubric của bộ dữ liệu.

Cách tổ chức này phản ánh đúng luồng xử lý thực tế của bài toán hiểu ẩn dụ: từ nhận diện → định vị → gán nhãn khái niệm → diễn giải → đánh giá chất lượng.

4.1.2. Các mô hình thử nghiệm

Nhóm lựa chọn bảy mô hình LLM có quy mô tương đương (khoảng 7–8B tham số) và chia thành 3 nhóm chính để đánh giá khả năng chuyển giao và thích nghi với tiếng Việt:

Nhóm 1 – Mô hình tối ưu cho tiếng Việt

Vistral-7B-Chat: Là mô hình hội thoại hướng tiếng Việt, phát triển từ nền Mistral 7B. Mô hình này được "Việt hoá" thông qua mở rộng tokenizer và huấn luyện tiếp trên dữ liệu tiếng Việt. Nhóm kỳ vọng Vistral sẽ có lợi thế rõ rệt khi xử lý các biểu thức ẩn dụ mang sắc thái văn hóa Việt.

VinaLLaMA-7B-Chat: Một đại diện phổ biến khác trong nhóm mô hình tiếng Việt, hỗ trợ định dạng prompt ChatML rõ ràng, thuận lợi cho thiết lập multitask yêu cầu đầu ra có cấu trúc.

Nhóm 2 – Mô hình đa ngữ khu vực Đông Nam Á (SEA)

SeaLLMs-v3-7B-Chat được phát triển theo hướng phục vụ nhiều ngôn ngữ trong khu vực Đông Nam Á, trong đó có tiếng Việt. Việc đưa mô hình này vào nhằm kiểm tra một giả thuyết thực tế: mô hình được tối ưu đa ngữ "vùng gần" có thể hiểu và diễn giải ẩn dụ tiếng Việt tốt hơn so với các mô hình đa ngữ chung

chung, nhờ nền tảng dữ liệu và chiến lược tinh chỉnh tập trung vào nhóm ngôn ngữ khu vực.

Nhóm 3 – Mô hình đa ngữ tổng quát (generalist)

Llama-3.1-8B-Instruct: Đại diện cho thế hệ mô hình ngôn ngữ mới (State-of-the-Art) với khả năng vượt trội trong việc tuân thủ hướng dẫn (instruction following) và hội thoại tự nhiên. Nhóm sử dụng mô hình này như một baseline "tổng quát nhưng mạnh mẽ" để quan sát mức độ hiệu quả khi áp dụng trực tiếp vào tiếng Việt, đặc biệt là ở các nhiệm vụ đòi hỏi khả năng suy luận sâu như phân loại và diễn giải ẩn dụ.

Qwen2.5-7B-Instruct: Được lựa chọn nhờ ưu điểm nổi bật về tính "kỷ luật" trong việc tuân thủ định dạng đầu ra, cụ thể là khả năng sinh cấu trúc JSON ổn định. Đây là yếu tố then chốt đối với thiết lập đa nhiệm (multitask) của đề tài. Mô hình giúp kiểm chứng xem liệu một mô hình đa ngữ tốt có thể duy trì cấu trúc đầu ra chuẩn xác ngay cả trong các cấu hình zero-shot hoặc few-shot hay không.

Aya-Expanse-8B: Là mô hình được phát triển với định hướng ưu tiên đa ngữ (multilingual-first), hỗ trợ diện rộng nhiều ngôn ngữ bao gồm tiếng Việt. Việc đưa Aya vào thử nghiệm đóng vai trò đối trọng, giúp nhóm phân tích xem liệu chiến lược tập trung vào sự đa dạng ngôn ngữ có mang lại lợi thế cụ thể nào trong các nhiệm vụ nhạy cảm về ngữ nghĩa và sắc thái (như chấm điểm diễn giải) so với các mô hình tổng quát khác.

Llama-2-7B-Chat: Là mô hình kinh điển, được sử dụng rộng rãi trong các nghiên cứu NLP trước đây. Mặc dù là kiến trúc cũ hơn, sự hiện diện của Llama-2 đóng vai trò quan trọng như một mốc tham chiếu chuẩn, giúp làm nổi bật sự tiến bộ

của các mô hình thế hệ mới (như Llama 3.1, Qwen) cũng như đo lường chính xác hiệu quả của các mô hình được tối ưu riêng cho tiếng Việt (như Vistral, VinaLLaMA).

4.2 Cài đặt thử nghiệm

4.2.1 Dữ liệu và phạm vi đánh giá

Thử nghiệm được triển khai trên bộ dữ liệu ViMUNCH đã trình bày ở Chương 3. Nhóm sử dụng tập train cho huấn luyện (khi fine-tuning), dev cho kiểm tra nhanh và rà soát chất lượng đầu ra, và báo cáo kết quả chính trên tập test nhằm đảm bảo tính khách quan. Các thống kê về phân bố nhãn, độ dài câu và tỉ lệ mẫu có đủ annotation (span/type/interpretation/scores) đã được phân tích ở Chương 3.

4.2.2 Hướng tiếp cận

Để đánh giá toàn diện năng lực mô hình trong các điều kiện triển khai khác nhau, mỗi mô hình được chạy theo ba cấu hình:

Zero-shot (ZS): Mô hình chỉ nhận mô tả nhiệm vụ và yêu cầu định dạng đầu ra, không được cung cấp ví dụ minh họa. Mục tiêu là đo năng lực "tự nhiên" của mô hình.

Few-shot (FS5): Bổ sung **5 ví dụ minh họa** (kèm chain-of-thought giải thích ngắn gọn nếu cần) vào prompt. Nhóm cố định bộ ví dụ cho tất cả mô hình để so sánh công bằng.

Fine-tuning (FT): Mô hình được tinh chỉnh trên tập huấn luyện của ViMUNCH, sau đó suy luận trong điều kiện Zero-shot.

Thiết kế ba hướng tiếp cận này giúp nhóm quan sát sự chuyển biến năng lực của mô hình: từ **khả năng suy luận tự nhiên** (Zero-shot), mức độ cải thiện khi **có**

ví dụ minh họa (Few-shot), đến hiệu quả của việc **thích nghi tham số chuyên sâu** (Fine-tuning). Các kết quả sẽ được đối chiếu theo từng task để xác định chiến lược phù hợp nhất cho bối cảnh hiểu ẩn dụ tiếng Việt.

4.2.3 Quy trình multitask và chuẩn hóa đầu ra

Nhóm triển khai quy trình multitask theo **hai luồng xử lý** để tách bạch mục tiêu của từng nhóm nhiệm vụ. **Luồng 1** tập trung vào việc mô hình hiểu câu đầu vào và tạo các đầu ra liên quan đến ẩn dụ (nhận diện, phân loại và diễn giải). **Luồng 2** được thiết kế riêng cho nhiệm vụ đánh giá, nơi mô hình đóng vai trò "giám khảo" và chấm điểm theo rubric của bộ dữ liệu. Cách tổ chức này giúp mô tả quy trình rõ ràng và thuận tiện khi tổng hợp kết quả theo từng nhóm nhiệm vụ.

Luồng 1 (Task 1–3: nhận diện – phân loại – diễn giải).

Mô hình nhận câu đầu vào và lần lượt dự đoán câu có ẩn dụ hay không; nếu có, mô hình xác định span ẩn dụ bằng cặp chỉ số **start/end** theo ký tự (start tính từ 0, end là vị trí kết thúc không bao gồm), sau đó gán loại ẩn dụ và sinh câu diễn giải theo nghĩa tường minh. Đối với phân loại, mô hình được ràng buộc chọn nhãn trong **tập nhãn xác định trước** nhằm tránh trường hợp tự tạo nhãn ngoài hệ thống.

Luồng 2 (Task 4: chấm điểm theo rubric).

Task 4 được triển khai tách khỏi luồng sinh diễn giải. Thay vì dựa trên diễn giải do mô hình tự tạo, mô hình nhận **câu gốc** kèm **diễn giải tham chiếu (gold)** và dự đoán điểm đánh giá theo rubric của bộ dữ liệu. Nhờ tách riêng như vậy, Task 4 phản ánh năng lực "chấm theo tiêu chí" một cách độc lập và nhất quán giữa các mô hình.

Để thuận tiện cho việc xử lý và tổng hợp kết quả, nhóm yêu cầu mô hình trả về **một đối tượng JSON duy nhất** theo schema thống nhất. Quy ước này giúp giảm lỗi lệch định dạng và đảm bảo đầu ra có thể được đọc tự động một cách ổn định.

4.2.4 Thiết lập suy luận và đảm bảo công bằng

Để đảm bảo so sánh công bằng giữa các mô hình, nhóm chuẩn hóa quy trình suy luận theo ba nguyên tắc chính. Thứ nhất, do các mô hình thuộc hai nhóm **Chat** và **Instruct**, nhóm sử dụng đúng **template hội thoại** theo khuyến nghị của từng mô hình (system/user/assistant hoặc định dạng tương đương), đồng thời giữ nội dung hướng dẫn và ràng buộc đầu ra tương đương giữa các mô hình để hạn chế sai lệch do prompt không phù hợp.

Thứ hai, nhóm ưu tiên thiết lập sinh văn bản theo hướng **ổn định và ít dao động**, tránh để yếu tố ngẫu nhiên chi phối kết quả (đặc biệt với các nhiệm vụ yêu cầu đầu ra có cấu trúc). Đồng thời, nhóm đặt giới hạn hợp lý cho độ dài đầu ra để hạn chế trường hợp mô hình trả lời lan man hoặc vượt khỏi phạm vi JSON cần thiết.

Thứ ba, nhóm thống nhất quy tắc xử lý các trường hợp đầu ra không hợp lệ. Khi mô hình trả về thiếu trường, sai cú pháp JSON hoặc kèm thêm phần giải thích, nhóm áp dụng cơ chế kiểm tra hợp lệ và xử lý theo một quy ước chung: ưu tiên trích xuất phần JSON hợp lệ nếu có thể; trường hợp không thể khôi phục theo schema thì đầu ra được đánh dấu không hợp lệ để tránh ảnh hưởng sai lệch đến tổng hợp kết quả.

4.2.5 Fine-Tuning

Bên cạnh các thiết lập suy luận trực tiếp (zero-shot và few-shot), nhóm thực hiện fine-tuning nhằm kiểm tra mức độ thích nghi của mô hình khi được học từ dữ

liệu của bài toán. Nhóm sử dụng **Supervised Fine-tuning (SFT)**[19] , trong đó mô hình được huấn luyện có giám sát trên các cặp đầu vào–đầu ra chuẩn của bộ dữ liệu theo schema, giúp mô hình nắm rõ yêu cầu nhiệm vụ và nhất quán hơn khi tạo đầu ra có cấu trúc.

Để tối ưu chi phí huấn luyện, nhóm áp dụng **LoRA (Low-Rank Adaptation)**[18]. Thay vì cập nhật toàn bộ tham số của mô hình, LoRA bổ sung các thành phần điều chỉnh nhỏ và chỉ tối ưu phần này. Cách tiếp cận giúp tiết kiệm tài nguyên nhưng vẫn cải thiện khả năng "bám nhiệm vụ" theo dữ liệu miền. Sau fine-tuning, mô hình được đánh giá lại theo cùng quy trình suy luận và cách chấm như các hướng tiếp cận còn lại để đảm bảo so sánh công bằng.

4.3 Độ đo đánh giá

Để đánh giá năng lực mô hình trong thiết lập đa nhiệm, nhóm sử dụng các độ đo phù hợp cho từng nhiệm vụ. Các độ đo được tính trên tập **test**. Trong đó, **Task 1A** được tính trên toàn bộ mẫu; các nhiệm vụ còn lại chủ yếu tính trên tập con phù hợp (ví dụ: các câu có ẩn dụ hoặc các câu có đủ thông tin tham chiếu). Đặc biệt, với **Task 3**, nhóm ưu tiên độ đo dựa trên tương đồng ngữ nghĩa thay vì chỉ dựa trên mức trùng khớp bề mặt câu chữ.

4.3.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification)

Task 1A là bài toán phân loại nhị phân: dự đoán câu **có ẩn dụ** hay **không có ẩn dụ**. Nhóm sử dụng bốn chỉ số chuẩn:

Precision (P): Trong các câu mô hình dự đoán "có ẩn dụ", tỷ lệ đúng là bao nhiêu.

$$P = \frac{TP}{TP + FP} \qquad (4.1)$$

Recall (R): Trong các câu thật sự có ẩn dụ, mô hình bắt được bao nhiêu.

$$R = \frac{TP}{TP + FN} \qquad (4.2)$$

F1-score: Trung bình điều hoà giữa Precision và Recall.

$$F1 = \frac{2PR}{P + R} \qquad (4.3)$$

Accuracy: Tỷ lệ dự đoán đúng trên toàn bộ mẫu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \qquad (4.4)$$

Trong đó TP, FP, FN, TN là số lượng true positive, false positive, false negative, true negative.

4.3.2 Task 1B: Trích xuất span ẩn dụ (Span Extraction)

Task 1B đánh giá mức độ mô hình xác định đúng vị trí biểu thức ẩn dụ trong câu. Mỗi span được biểu diễn bằng cặp chỉ số **start/end theo ký tự** (start tính từ 0; end là vị trí kết thúc không bao gồm).

Gọi G là tập ký tự thuộc span tham chiếu (gold), P là tập ký tự thuộc span dự đoán. Nhóm sử dụng:

Overlap Precision / Recall / F1 (tính theo ký tự):

$$Prec_{span} = \frac{|P \cap G|}{|P|} \qquad (4.5),$$

$$Rec_{span} = \frac{|P \cap G|}{|G|} \qquad (4.6),$$

$$F1_{span} = \frac{2Prec_{span} . Rec_{span}}{Prec_{span} + Rec_{span}} \qquad (4.7)$$

IoU (Intersection over Union): đo mức độ chồng lắp tương đối giữa hai span.

$$IoU = \frac{|P \cap G|}{|P \cup G|} \qquad (4.8)$$

Exact Match (EM): đúng tuyệt đối ranh giới span. Nếu P = G thì EM = 1. Ngược lại, EM = 0.

Trường hợp một câu có nhiều span, các chỉ số có thể được tính theo từng span và lấy trung bình theo mẫu. Ngoài ra, để kiểm soát xu hướng mô hình "bịa span", nhóm báo cáo thêm:

FP span rate trên câu không ẩn dụ: tỷ lệ câu **không có ẩn dụ** (theo gold) nhưng mô hình vẫn trích xuất span.

$$FP_span_rate = \frac{1}{N_{neg}} \sum_{i \in Neg} 1_{span}(i) \qquad (4.9)$$

Trong đó N_{neg} là số câu không ẩn dụ theo gold, và $1_{span}(i)$ =1 nếu mô hình dự đoán có ít nhất một span (không rỗng), ngược lại bằng 0.

4.3.3 Task 2: Phân loại ẩn dụ (Metaphor Classification)

Task 2 là bài toán **đa nhãn**: mỗi câu có thể thuộc nhiều loại ẩn dụ. Nhóm dùng ba chỉ số:

Micro-F1: gộp tất cả nhãn của mọi mẫu lại, sau đó tính F1 (ưu tiên lớp xuất hiện nhiều).

$$P_{\mu} = \frac{\Sigma TP}{\Sigma(TP + FP)} \qquad (4.10),$$

$$R_{\mu} = \frac{\Sigma TP}{\Sigma(TP + FN)} \qquad (4.11),$$

$$F1_{\mu} = \frac{2P_{\mu} . R_{\mu}}{P_{\mu} + R_{\mu}} \qquad (4.12)$$

Macro-F1: tính F1 cho từng nhãn rồi lấy trung bình (coi các nhãn quan trọng như nhau).

$$F1_{macro} = \frac{1}{L}\sum_{l=1}^{L} F1_{l} \qquad (4.13)$$

với L là số nhãn.

Subset Accuracy: chỉ tính đúng khi dự đoán **khớp toàn bộ tập nhãn** của mẫu. Nếu $\widehat{Y} = Y$, $SubsetAcc = 1$. Ngược lại, $SubsetAcc = 0$.

4.3.4 Task 3: Diễn giải ẩn dụ (Interpretation)

Task 3 yêu cầu mô hình sinh diễn giải theo nghĩa tường minh. Vì mục tiêu của đề tài tập trung vào **mức độ hiểu ngữ nghĩa**, nhóm ưu tiên độ đo dựa trên **tương đồng ngữ nghĩa** giữa diễn giải dự đoán và diễn giải tham chiếu.

Embedding Cosine Similarity (chỉ số chính): Mỗi diễn giải được mã hoá thành vector embedding bằng mô hình sentence embedding tiếng Việt.

VoVanPhuc/sup-SimCSE-VietNamese-phobert-base [20]. Gọi u là embedding của diễn giải dự đoán và v là embedding của diễn giải tham chiếu, độ tương đồng cosine được tính:

$$CosSim(u, v) = \frac{u \,.\, v}{||u||\,||v||} \qquad (4.14)$$

Điểm Task 3 được tổng hợp bằng cách lấy trung bình CosSim trên các mẫu hợp lệ.

ROUGE-L (dựa trên LCS)[22]: dựa trên độ dài chuỗi con chung dài nhất LCS($\hat{s}$,s) giữa diễn giải dự đoán $\hat{s}$ và tham chiếu s.

$$R = \frac{LCS(\hat{s}, s)}{|s|} \qquad (4.15),$$

$$P = \frac{LCS(\hat{s}, s)}{|\hat{s}|} \qquad (4.16),$$

$$ROUGE - L_{F1} = \frac{2PR}{P+R} \qquad (4.17)$$

chrF [23]: F-score dựa trên mức trùng khớp **n-gram ký tự**, phù hợp hơn khi có biến thể từ/cách viết trong tiếng Việt. (chrF được tính bằng F-score giữa precision và recall của các n-gram ký tự theo cấu hình chuẩn.)

4.3.5 Task 4: Chấm điểm diễn giải (Paraphrase Judgement)

Task 4 đánh giá khả năng mô hình chấm điểm theo rubric của bộ dữ liệu trên **diễn giải tham chiếu (gold)**. Do thang điểm mang tính thứ bậc, nhóm sử dụng:

MAE (chỉ số chính): độ lệch tuyệt đối trung bình giữa điểm dự đoán và điểm gold:

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |\widehat{y_i} - y_i| \qquad (4.18)$$

QWK – Quadratic Weighted Kappa (chỉ số chính): đo mức đồng thuận có xét mức "nặng nhẹ" của sai lệch. Với K mức điểm, trọng số:

$$w_{ij} = \frac{(i-j)^2}{(K-1)^2} \quad \text{và} \quad k = 1 - \frac{\Sigma_{ij} w_{ij} O_{ij}}{\Sigma_{ij} w_{ij} E_{ij}} \qquad (4.19)$$

trong đó O là ma trận quan sát (confusion matrix theo mức điểm) và E là ma trận kỳ vọng (từ phân phối biên).

4.3.6 Tóm tắt phạm vi tính độ đo theo nhiệm vụ

Đối với Task 1A, các chỉ số được tính trên toàn bộ tập test, trong khi với Task 1B, các phép đo được thực hiện trên các mẫu có ẩn dụ theo nhãn gold, riêng FP span rate được tính trên các mẫu không có ẩn dụ; tiếp đó, Task 2 và Task 3 chỉ

được tính trên các mẫu có ẩn dụ và có đầy đủ các trường tham chiếu tương ứng, còn Task 4 được tính trên các mẫu có diễn giải tham chiếu và điểm gold đầy đủ.

4.4 Kết quả thử nghiệm

Các kết quả được báo cáo trên tập **test (n=1701)**. Trong đó, Task 1 (metaphor identification + span extraction) có **637** mẫu dương tính (có ẩn dụ) và **1064** mẫu âm tính (không ẩn dụ). Task 3 (metaphor interpretation) và Task 4 (paraphrase judgement) được tính trên tập con các mẫu có đầy đủ trường tham chiếu, với **n=631**.

4.4.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification)

Bảng 4.1 trình bày kết quả task 1A trên tập test. Độ đo chính là F1 (positive class), kèm các độ đo phụ gồm Precision, Recall và Accuracy trong ba thiết lập ZS/FS/FT.

Bảng 4.1: Kết quả thử nghiệm nhiệm vụ nhận diện ẩn dụ

Mô hình	Thiết lập	F1	Precision	Recall	Accuracy
Qwen2.5-7B	Zero-shot	0.632553	0.484167	0.912088	0.603175
	Few-shot	**0.677561**	0.56499	0.846154	0.698413
	Fine-tuned	0.757072	0.80531	0.714286	0.828336
SeALLMs-v3-7B	**Zero-shot**	**0.648976**	0.627566	0.6719	0.727807
	Few-shot	0.654845	0.548832	0.811617	0.6796

	Fine-tuned	0.739093	0.81203	0.678179	0.820694
VinaLlama-7B	Zero-shot	0.602196	0.451411	0.904239	0.552616
	Few-shot	0.614555	0.46798	0.894819	0.579659
	Fine-tuned	0.720339	0.782689	0.66719	0.805996
Vistral-7B-Chat	Zero-shot	0.560681	0.392231	0.982732	0.42328
	Few-shot	0.609086	0.446559	0.957614	0.539683
	Fine-tuned	**0.771845**	0.796327	0.748823	0.834215
Aya-Expanse-8B	Zero-shot	0.54946	0.379023	0.99843	0.386831
	Few-shot	0.560932	0.392476	0.982732	0.423868
	Fine-tuned	0.730703	0.805293	0.66876	0.815403
Llama-3.1-8B	Zero-shot	0.545533	0.37619	0.992151	0.380952
	Few-shot	0.553995	0.384522	0.990581	0.402704
	Fine-tuned	0.739865	0.800731	0.687598	0.81893
Llama-2-7B	Zero-shot	0.538595	0.372079	0.974882	0.374486
	Few-shot	0.544288	0.374118	0.99843	0.373898
	Fine-tuned	0.524409	0.526066	0.522763	0.644915

4.4.2. Task 1B: Trích xuất span ẩn dụ (Span Extraction)

Bảng 4.2 trình bày kết quả task 1B. Độ đo chính là Overlap-F1 (theo ký tự), kèm các độ đo phụ gồm IoU, Exact Match và FP span rate trên các câu không ẩn dụ (càng thấp càng tốt).

Bảng 4.2: Kết quả thử nghiệm nhiệm vụ trích xuất span ẩn dụ

Mô hình	Thiết lập	Overlap-F1(pos)	IoU(pos)	EM(pos)	FP-span-rate(neg)
Vistral-7B-Chat	Zero-shot	0.411092	0.348061	0.152276	0.794173
	Few-shot	**0.557697**	0.476553	0.174254	0.678571
	Fine-tuned	**0.564401**	0.505568	0.268446	0.113722
Llama-3.1-8B	**Zero-shot**	**0.565832**	0.465927	0.119309	0.967105
	Few-shot	0.544712	0.467659	0.193093	0.883459
	Fine-tuned	0.495265	0.436616	0.211931	0.101504
Aya-Expanse-8B	Zero-shot	0.444777	0.381816	0.175824	0.766917
	Few-shot	0.492698	0.430378	0.196232	0.75282
	Fine-tuned	0.471112	0.417309	0.208791	0.093985
Qwen2.5-7B	Zero-shot	0.424631	0.356136	0.142857	0.520677
	Few-shot	0.450757	0.389128	0.174254	0.349624
	Fine-tuned	0.514705	0.456866	0.22606	0.102444
Llama-2-7B	Zero-shot	0.486895	0.391932	0.070644	0.860902
	Few-shot	0.435171	0.351286	0.081633	0.758459
	Fine-tuned	0.229526	0.183083	0.051805	0.267857
SeALLMs-v3-7B	Zero-shot	0.255511	0.204884	0.086342	0.213346
	Few-shot	0.405148	0.33778	0.138148	0.37406

	Fine-tuned	0.478005	0.424963	0.213501	0.091165
VinaLlama-7B	Zero-shot	0.242032	0.198767	0.076923	0.354323
	Few-shot	0.384984	0.314836	0.094192	0.477444
	Fine-tuned	0.396863	0.347445	0.172684	0.097744

4.4.3. Task 2: Phân loại loại ẩn dụ (Metaphor Classification)

Bảng 4.3 báo cáo kết quả task 2. Độ đo chính là Macro-F1, kèm các độ đo phụ gồm Micro-F1 và Subset Accuracy.

Bảng 4.3: Kết quả thử nghiệm nhiệm vụ phân loại loại ẩn dụ

Mô hình	Thiết lập	Macro-F1	Micro-F1	Subset-Acc
Vistral-7B-Chat	Zero-shot	0.155518	0.274818	0.138148
	Few-shot	**0.278044**	0.485537	0.150706
	Fine-tuned	**0.327005**	0.555494	0.230769
Aya-Expanse-8B	Zero-shot	0.215929	0.4751	0.22135
	Few-shot	0.277902	0.517094	0.215071
	Fine-tuned	0.274341	0.532497	0.189953
Qwen2.5-7B	**Zero-shot**	**0.229621**	0.388326	0.163265
	Few-shot	0.261281	0.45006	0.161695
	Fine-tuned	0.316473	0.535068	0.204082
Llama-3.1-8B	Zero-shot	0.221338	0.385417	0.152276
	Few-shot	0.230536	0.456728	0.191523
	Fine-tuned	0.268068	0.525848	0.191523
Llama-2-7B	Zero-shot	0.157954	0.430211	0.161695

	Few-shot	0.230052	0.502749	0.164835
	Fine-tuned	0.164503	0.388451	0.097331
SeALLMs-v3-7B	Zero-shot	0.173779	0.320166	0.128728
	Few-shot	0.217103	0.395845	0.139717
	Fine-tuned	0.298503	0.530795	0.174254
VinaLlama-7B	Zero-shot	0.09251	0.229114	0.10832
	Few-shot	0.207801	0.351873	0.083203
	Fine-tuned	0.250812	0.520344	0.194662

4.4.4. Task 3: Diễn giải ẩn dụ (Metaphor Interpretation)

Bảng 4.4 báo cáo kết quả task 3. Độ đo chính là Embedding Cosine Similarity (sentence embeddings), kèm các độ đo phụ gồm ROUGE-L và chrF.

Bảng 4.4: Kết quả thử nghiệm nhiệm vụ diễn giải ẩn dụ

Mô hình	Thiết lập	SimCSE-Cosine	ROUGE-L(F1)	chrF
Vistral-7B-Chat	Zero-shot	0.618351	0.260344	0.234321
	Few-shot	**0.705921**	0.345885	0.325227
	Fine-tuned	**0.597836**	0.356748	0.34685
Llama-3.1-8B	**Zero-shot**	**0.625464**	0.20217	0.243229
	Few-shot	0.695232	0.33726	0.313692
	Fine-tuned	0.542318	0.324227	0.31026
Aya-Expanse-8B	Zero-shot	0.613835	0.13361	0.249306
	Few-shot	0.672163	0.23078	0.285069
	Fine-tuned	0.529585	0.306731	0.298116

Llama-2-7B	Zero-shot	0.588365	0.203918	0.276714
	Few-shot	0.655009	0.311448	0.32944
	Fine-tuned	0.416224	0.254302	0.257013
SeALLMs-v3-7B	Zero-shot	0.452841	0.175976	0.195584
	Few-shot	0.571023	0.26057	0.252974
	Fine-tuned	0.528657	0.301518	0.291893
Qwen2.5-7B	Zero-shot	0.529063	0.130795	0.185038
	Few-shot	0.55432	0.209944	0.201506
	Fine-tuned	0.563148	0.325244	0.310349
VinaLlama-7B	Zero-shot	0.578267	0.200951	0.270977
	Few-shot	0.550457	0.279245	0.267318
	Fine-tuned	0.528964	0.308868	0.295527

4.4.5. Task 4: Chấm điểm theo rubric (Paraphrase Judgement)

Bảng 4.5 báo cáo kết quả task 4. Các độ đo chính gồm QWK và MAE (MAE càng thấp càng tốt) trong các thiết lập ZS/FS/FT.

Bảng 4.5: Kết quả thử nghiệm nhiệm vụ đánh giá diễn giải ẩn dụ

Mô hình	Thiết lập	QWK(avg)	MAE(avg)	Acc(±1)(avg)
Qwen2.5-7B	Zero-shot	0.057345	0.651347	0.907092
	Few-shot	**0.077674**	0.316165	0.972662
	Fine-tuned	0.173821	0.162837	0.977021
SeALLMs-v3-7B	**Zero-shot**	**0.065764**	0.383914	0.919572
	Few-shot	0.065764	0.383914	0.919572

	Fine-tuned	0.168388	0.159865	0.976624
Aya-Expanse-8B	Zero-shot	0.014545	0.393621	0.967512
	Few-shot	0.014545	0.393621	0.967512
	Fine-tuned	0.143377	0.163233	0.977219
VinaLlama-7B	Zero-shot	0.009587	0.615095	0.839739
	Few-shot	0.008472	0.478972	0.940531
	Fine-tuned	0.087034	0.165808	0.975238
Llama-3.1-8B	Zero-shot	0.002696	2.06874	0.467512
	Few-shot	0.002696	2.06874	0.467512
	Fine-tuned	0.224818	0.154517	0.979596
Llama-2-7B	Zero-shot	-0.000292	2.046553	0.406894
	Few-shot	-0.000292	2.046553	0.406894
	Fine-tuned	0.00023	0.190967	0.971276
Vistral-7B-Chat	Zero-shot	-0.010963	0.830428	0.974049
	Few-shot	-0.004328	0.189778	0.970285
	Fine-tuned	**0.287469**	0.148177	0.981775

4.5 Phân tích lỗi và thảo luận

Nhìn tổng thể, kết quả thử nghiệm cho thấy ba hiện tượng nổi bật cần được nhấn mạnh:

(i) Thiên lệch dương tính (positive bias) ở thiết lập **Zero-shot** khiến mô hình "nhìn ra ẩn dụ" quá tay (Task 1A/1B).

(ii) Đánh đổi giữa "bám nghĩa" và "bám chữ" ở bài toán sinh diễn giải (Task 3), đặc biệt sau **Fine-tuning** khi một số chỉ số bề mặt tăng nhưng tương đồng ngữ nghĩa giảm.

(iii) "Lột xác" ở Task 4 (Paraphrase Judgement): prompt (zero/few-shot) gần như không đủ để học rubric; Fine-tuning mới giúp mô hình hình thành hành vi chấm điểm có cấu trúc và gần người hơn.

4.5.1 Task 1A: Nhận diện ẩn dụ (Metaphor Identification)

Theo Bảng 4.1, ở **Zero-shot**, các mô hình thường có **Recall cao nhưng Precision thấp**, làm F1 dao động quanh mức trung bình và phản ánh xu hướng **positive bias** (ưu tiên "bắt cho đủ", chấp nhận báo nhầm).

Khi chuyển sang **Few-shot**, F1 nhìn chung cải thiện; đáng chú ý **Qwen2.5-7B** dẫn đầu nhóm prompt với F1 xấp xỉ **0.678.**

Bước ngoặt rõ nhất đến từ **Fine-tuning**: đa số mô hình tăng F1 lên vùng **0.72–0.77**; **Vistral-7B-Chat nổi bật với F1 ≈ 0.772 và Accuracy ≈ 83.4%**, cao nhất bảng xếp hạng. Điều này cho thấy tinh chỉnh theo miền giúp mô hình "chốt tiêu chí" ẩn dụ ổn định hơn.

Ví dụ, câu: *"Tôi thích nhất mùa hè trên núi quê tôi."* (id 66), được gán nhãn chuẩn **have_metaphor = 0**. Ở **Zero-shot**, mô hình lại suy diễn cụm "mùa hè trên núi quê tôi" như một biểu tượng trừu tượng, dẫn đến dự đoán nhầm **có ẩn dụ**. Sang **Few-shot/Fine-tuning**, mô hình có xu hướng quay về cách hiểu đúng: đây là biểu đạt trực tiếp, không kích hoạt ánh xạ ẩn dụ. Ví dụ này cụ thể hóa **Hiện tượng (i)**: khi chưa có ví dụ và tiêu chí rõ ràng để bám theo, mô hình dễ gán nhãn ẩn dụ cả với những câu chỉ mang nghĩa tả thực.

4.5.2 Task 1B: Trích xuất span ẩn dụ (Span Extraction)

Bảng 4.2 cho thấy một nghịch lý phổ biến: **Overlap-F1** ở **Zero-shot** đôi khi không quá thấp (ví dụ Llama-3.1-8B đạt **0.5658**) nhưng **FP-span-rate(neg)** lại cực lớn, nghĩa là mô hình **trích xuất thừa** cả trên các câu không ẩn dụ.

Với **Vistral-7B-Chat**, chuyển từ Zero-shot sang Few-shot giúp tăng Overlap-F1 từ **0.4111 → 0.5577**, nhưng FP-span-rate vẫn cao (**0.7942 → 0.6786**), cho thấy few-shot cải thiện định vị nhưng chưa "kìm tay" được việc trích xuất nhầm. Sau **Fine-tuning**, điểm Overlap-F1 của Vistral giữ ở mức cao (**0.5644**) và quan trọng nhất là **FP-span-rate giảm mạnh xuống 0.1137**. Đây là dấu hiệu mô hình học được "khi nào nên trích xuất, khi nào không".

Ví dụ, câu *"Tôi thích nhất mùa hè trên núi quê tôi."* (id 66), được gán nhãn chuẩn **không ẩn dụ**. **Zero-shot** dễ "gán span" cho một cụm danh ngữ bất kỳ (vì đang cố tìm một biểu thức ẩn dụ để khớp nhiệm vụ). **Fine-tuning** giúp mô hình kiểm soát tốt hơn: nếu câu không ẩn dụ thì **không trích span**. Ví dụ này củng cố **Hiện tượng (i)** ở mức "span": không chỉ gán nhãn dương tính giả, mà còn kéo theo hành vi trích xuất dương tính giả.

4.5.3 Task 2: Phân loại loại ẩn dụ (Metaphor Classification)

Đây là bài toán **đa nhãn** nên khó hơn phân loại nhị phân. Bảng 4.3 cho thấy **Zero-shot** gần như không hiệu quả: **Macro-F1 chỉ ~0.15–0.23** (mô hình chưa nắm hệ nhãn 5 loại).

Sang **Few-shot**, Vistral-7B-Chat đạt **Macro-F1 ≈ 0.278**, chứng tỏ ví dụ minh họa giúp mô hình "hiểu luật chơi" tốt hơn. Tuy nhiên, **Fine-tuning** mới tối ưu nhất: Vistral tiếp tục dẫn đầu với **Macro-F1 ≈ 0.327**, đồng thời các chỉ số Micro-F1 và Subset Accuracy cũng tăng. Ví dụ, trong Bảng 3.3, câu văn miêu tả "đêm tối dày

đặc… hun hút như lối đi vào một thế giới tăm tối…" được gán **đồng thời** hai nhãn: **Ontological** và **Emotional**. Điểm khó nằm ở chỗ: cùng một hình ảnh vừa "vật thể hóa khái niệm trừu tượng" (bản thể), vừa gợi cảm giác bế tắc, u buồn (cảm xúc). Lỗi thường gặp ở zero-shot/few-shot là mô hình **chỉ chọn 1 nhãn nổi bật** hoặc **gán nhãn theo từ khóa**, làm Macro-F1 thấp. Ví dụ này cho thấy vì sao Fine-tuning đem lại lợi ích rõ: mô hình cần học ranh giới khái niệm giữa các loại ẩn dụ và cách "chấp nhận đa nhãn".

4.5.4 Task 3: Diễn giải ẩn dụ (Metaphor Interpretation)

Task 3 là nhiệm vụ sinh văn bản nên khó nhất; thước đo chính là **Cosine SimCSE** giữa diễn giải và câu tham chiếu. Bảng 4.4 cho thấy **Vistral-7B-Chat** tăng mạnh từ **Cosine ≈ 0.6196 (Zero-shot)** lên ≈ **0.7062 (Few-shot)**, phản ánh vai trò "định hướng văn phong/chiến lược diễn giải" của ví dụ mẫu. Tuy nhiên, khi **Fine-tuning**, **Cosine giảm** (Vistral xuống ≈ **0.5979**), trong khi **ROUGE-L/chrF lại tăng** (ROUGE-L ≈ 0.7591; chrF ≈ 0.5320).

Đây chính là **Hiện tượng (ii)**: sau Fine-tuning, mô hình có thể học tốt "khuôn câu" (tăng khớp bề mặt) nhưng mất bớt linh hoạt trong diễn đạt nghĩa sâu (giảm tương đồng embedding). Ví dụ với câu gốc *"Tôi đã thấy hạt thời gian trên da tay mẹ." (*id=2092). Với thiết lập **Zero-shot**, mô hình có xu hướng lặp/giữ nguyên cụm ẩn dụ (kiểu "hạt thời gian…"), cho thấy diễn giải chưa "lộ nghĩa", còn mơ hồ. Với thiết lập, **Few-shot**, mô hình diễn đạt theo hướng giải thích ý niệm (ví dụ quy đổi "hạt thời gian" thành dấu vết/nếp nhăn của thời gian trên da tay) → thường giúp Cosine cao hơn vì nghĩa được tường minh. Sang **Fine-tuning,** mô hình dễ sinh câu theo template gần câu gốc (giữ cấu trúc, thay ít từ) → ROUGE/chrF tăng nhưng không đảm bảo Cosine tăng.

4.5.5 Task 4: Chấm điểm theo rubric (Paraphrase Judgement)

Bảng 4.5 khẳng định đây là tác vụ mà **prompting gần như bất lực**: QWK ở **Zero-shot/Few-shot** rất thấp, xấp xỉ 0 hoặc âm; trong khi phần lớn các LLMs theo hướng **Fine-tuning** đưa QWK lên mức **0.14–0.29** và giảm MAE rõ rệt. Đáng chú ý, **Vistral-7B-Chat** dẫn đầu với **QWK ≈ 0.288** và độ chính xác (±1 điểm) khoảng **98%**, cho thấy fine-tuning giúp mô hình học được "thang đo" và mức độ nghiêm khắc gần người hơn.

Đây là **Hiện tượng (iii)**: năng lực chấm theo rubric chỉ hình thành khi có huấn luyện giám sát. Ví dụ với id = 5875, câu gốc là "Giờ thì không có tấm rèm nào xen giữa ngài và nguồn sáng nữa." và câu diễn giải là "Giờ thì không có tấm rèm nào xen giữa ngài và ánh sáng soi tỏ của sự thật nữa.", trong đó điểm tham chiếu do người chấm đưa ra lần lượt là Overall = 3.2 và Quality = 3.0; ở các dự đoán của mô hình theo từng thiết lập, với zero-shot mô hình cho điểm Overall = 1.0, Quality = 1.0, với few-shot điểm số lại tăng mạnh lên Overall = 4.0, Quality = 4.0, trong khi ở thiết lập fine-tuned kết quả là Overall = 3.1, Quality = 2.83, vì vậy có thể thấy rằng ở hai thiết lập không tinh chỉnh, điểm số dao động theo hướng cực trị (quá thấp hoặc quá cao) và lệch đáng kể so với người chấm, còn sau tinh chỉnh, dự đoán tiến gần hơn và ổn định hơn quanh mức tham chiếu, qua đó phản ánh việc mô hình đã học được cách quy chiếu chất lượng diễn giải vào thang điểm của rubric.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Trong khóa luận tốt nghiệp này, chúng tôi tập trung xây dựng một bộ ngữ liệu thử thách nhằm đánh giá năng lực hiểu ẩn dụ tiếng Việt của các mô hình ngôn ngữ lớn (LLMs). Trên cơ sở quy trình thu thập, xử lý, chú thích dữ liệu và thử nghiệm đánh giá, khóa luận đạt được các kết quả chính như sau:

(1) Xây dựng thành công bộ ngữ liệu ViMUNCH, gồm 8.500 cặp câu ẩn dụ – câu diễn giải, được chú thích theo thiết kế đa nhiệm: nhận diện ẩn dụ, trích xuất span ẩn dụ, phân loại loại ẩn dụ (đa nhãn), diễn giải nghĩa tường minh và chấm điểm diễn giải theo rubric. Bên cạnh nhãn nhiệm vụ, dữ liệu còn bao gồm các thông tin hỗ trợ phân tích như chất lượng diễn giải và mức độ tương đồng so với tham chiếu, tạo điều kiện cho đánh giá toàn diện cả năng lực hiểu lẫn năng lực sinh của mô hình.

(2) Tiến hành thử nghiệm hệ thống trên 7 mô hình LLM quy mô 7–8B, bao gồm các mô hình tối ưu cho tiếng Việt (Vistral-7B-Chat, VinaLLaMA-7B-Chat), mô hình đa ngữ khu vực (SeaLLMs-v3-7B-Chat), các mô hình đa ngữ tổng quát (Llama-3.1-8B-Instruct, Qwen2.5-7B-Instruct, Aya-Expanse-8B, Llama-2-7B-Chat). Các mô hình được đánh giá trong ba cấu hình zero-shot, few-shot (5 ví dụ), fine-tuning. Fine-tuning được triển khai bằng SFT kết hợp LoRA nhằm đảm bảo hiệu quả chi phí và tính công bằng khi so sánh.

(3) Kết quả cho thấy năng lực của LLM phụ thuộc mạnh vào cách triển khai và bản chất nhiệm vụ. Ở các nhiệm vụ có cấu trúc như Task 1A/1B/Task 2, mô hình ở thiết lập zero-shot thường có xu hướng "bắt ẩn dụ rộng" (Recall cao) nhưng kéo theo Precision thấp và đặc biệt dễ xuất hiện lỗi trích span trên câu không ẩn dụ.

Few-shot giúp mô hình bám sát yêu cầu định dạng/tiêu chí hơn, từ đó cải thiện đáng kể F1 và chất lượng đầu ra. Tuy nhiên, fine-tuning tạo ra cải thiện ổn định và nhất quán nhất ở nhóm nhiệm vụ này, thể hiện rõ ở việc tăng F1 và giảm mạnh lỗi FP span sau tinh chỉnh; trong nhóm mô hình thử nghiệm, Vistral-7B-Chat cho thấy lợi thế rõ rệt khi thích nghi theo dữ liệu tiếng Việt và thường đạt kết quả dẫn đầu sau fine-tuning, trong khi mô hình đa ngữ phiên bản cũ (điển hình Llama-2-7B-Chat) khó thích nghi và có thể suy giảm hiệu năng ở một số thiết lập.

(4) Với các nhiệm vụ mang tính sinh và đánh giá ngữ nghĩa sâu, xu hướng trở nên phân hóa hơn. Task 3 (diễn giải ẩn dụ) là thách thức lớn nhất: few-shot giúp cải thiện rõ chất lượng diễn giải nhờ định hướng phong cách và yêu cầu đầu ra, nhưng fine-tuning không luôn làm tăng tương đồng ngữ nghĩa theo embedding cosine (trong khi các chỉ số khớp bề mặt như ROUGE/chrF có thể tăng), gợi ý rằng mô hình có xu hướng "bám" câu tham chiếu về từ ngữ hơn là cải thiện hiểu sâu. Ngược lại, Task 4 (chấm điểm theo rubric) cho thấy fine-tuning là điều kiện gần như bắt buộc: ở zero-shot/few-shot, mô hình khó bắt chước cách chấm của con người (QWK thấp), nhưng sau fine-tuning, mức đồng thuận với nhãn gold tăng mạnh và sai số giảm rõ rệt; kết quả tốt nhất tiếp tục thuộc về các mô hình thích nghi tốt với tiếng Việt và dữ liệu miền.

Từ các kết quả trên, có thể kết luận rằng các LLM 7–8B có khả năng thực hiện chuỗi nhiệm vụ từ nhận diện – định vị – phân loại – diễn giải đến chấm điểm, nhưng hiệu năng còn phụ thuộc lớn vào thiết lập suy luận và mức độ thích nghi theo dữ liệu miền. Chúng tôi kỳ vọng ViMUNCH sẽ đóng vai trò như một cơ sở dữ liệu chuẩn để so sánh, đánh giá và phân tích sâu năng lực hiểu ẩn dụ tiếng Việt của LLMs, đồng thời mở ra hướng nghiên cứu tiếp theo về cải thiện diễn giải ẩn dụ theo

ngữ nghĩa (beyond lexical overlap) và nâng cao độ tin cậy của các mô hình chấm điểm theo rubric.

5.2. Hạn chế

Trong quá trình xây dựng bộ ngữ liệu ViMUNCH và thử nghiệm trên các mô hình ngôn ngữ lớn (LLMs), bên cạnh những kết quả thuận lợi, chúng tôi cũng nhận thấy một số hạn chế còn tồn đọng.

Bộ ngữ liệu ViMUNCH hiện vẫn tồn tại hiện tượng mất cân bằng giữa các loại ẩn dụ, trong đó một số loại xuất hiện với tần suất thấp do đặc thù nguồn dữ liệu và tính hiếm của hiện tượng ngôn ngữ. Sự mất cân bằng này có thể ảnh hưởng đến khả năng học và đánh giá công bằng của mô hình, đặc biệt đối với các nhiệm vụ phân loại đa nhãn.

Mặc dù ViMUNCH đã áp dụng quy trình gán nhãn và đánh giá nhiều bước, một số nhiệm vụ, đặc biệt là diễn giải ẩn dụ và chấm điểm theo rubric, vẫn chịu ảnh hưởng nhất định từ yếu tố chủ quan của annotator. Điều này đặt ra thách thức trong việc đảm bảo tính nhất quán tuyệt đối và khả năng tái lập của benchmark.

Do hạn chế về tài nguyên tính toán, các thử nghiệm trong khóa luận mới chỉ tập trung vào các mô hình LLM quy mô 7–8B tham số, chưa khảo sát được tác động của quy mô mô hình lớn hơn đối với khả năng hiểu ẩn dụ tiếng Việt.

5.3. Hướng phát triển

Trong tương lại, chúng tôi đề xuất mở rộng phạm vi thu thập dữ liệu từ nhiều nguồn văn bản khác nhau, bao gồm các thể loại và miền ngữ cảnh đa dạng hơn, đồng thời xem xét các chiến lược chọn mẫu có định hướng nhằm cải thiện phân bố nhãn và tăng độ đại diện của các loại ẩn dụ ít gặp.

Chúng tôi sẽ tiếp tục hoàn thiện guideline gán nhãn, làm rõ các tiêu chí đánh giá và mở rộng các ví dụ minh họa, đồng thời nghiên cứu các cơ chế kiểm soát chất lượng bổ sung như đánh giá nhiều vòng hoặc chuẩn hóa thông qua thảo luận liên annotator.

Cuối cùng, nghiên cúu sẽ mở rộng quy mô thử nghiệm trên các mô hình ngôn ngữ lớn hơn (trên 13B tham số) hoặc các mô hình thương mại mạnh mẽ để kiểm chứng giới hạn năng lực hiểu ẩn dụ và đánh giá tác động của quy mô mô hình (scaling law) đối với tiếng Việt.

CAM KẾT SỬ DỤNG DỮ LIỆU

Dữ liệu sử dụng trong khóa luận này được thu thập từ nguồn công khai trên Internet - Báo Văn Nghệ Online (baovannghe.vn), phục vụ hoàn toàn cho mục đích học thuật, nghiên cứu và phi thương mại. Các tài liệu được thu thập chỉ được sử dụng cho quá trình tiền xử lý, phân tích ngôn ngữ và gán nhãn nhằm xây dựng bộ ngữ liệu nghiên cứu về hiện tượng ẩn dụ trong tiếng Việt.

Nhóm nghiên cứu cam kết không tái xuất bản, phân phối, khai thác thương mại hoặc công bố nguyên văn các bài viết từ các nguồn nêu trên dưới bất kỳ hình thức nào. Dữ liệu công bố trong khóa luận và các kết quả liên quan chỉ bao gồm các câu đơn lẻ đã được tiền xử lý, trích xuất hoặc diễn giải lại phục vụ cho mục đích minh họa và phân tích khoa học, đồng thời luôn ghi rõ nguồn gốc dữ liệu nhằm đảm bảo tính minh bạch và tôn trọng quyền tác giả.

Việc sử dụng dữ liệu trong phạm vi khóa luận tuân thủ các nguyên tắc đạo đức nghiên cứu, các quy định về quyền tác giả hiện hành và chỉ nhằm đóng góp cho mục tiêu nghiên cứu khoa học và giáo dục.

TÀI LIỆU THAM KHẢO

[1] Lakoff, George & Johnson, Mark (1980). Metaphors We Live By. University of Chicago Press.

[2] G. J. Steen, A. G. Dorst, J. B. Herrmann, A. A. Kaal, T. Krennmayr, and T. Pasma, “A method for linguistic metaphor identification: From MIP to MIPVU,” Amsterdam: John Benjamins Publishing, 2010.

[3] E. Shutova, “Design and evaluation of metaphor processing systems”, Ph.D. dissertation, University of Cambridge, 2010.

[4] Y. Bizzoni and S. Lappin, “A corpus and evaluation methodology for metaphor paraphrase,” Proceedings of COLING 2018, pp. 2616–2626, 2018.

[5] R. Joseph, T. Liu, A. B. Ng, S. See, and S. Rai, "NewsMet : A ‘do it all’ Dataset of Contemporary Metaphors in News Headlines," *Findings of the Association for Computational Linguistics: ACL 2023*, pp. 10090–10104, Jul. 2023.

[6] X. Tong, R. Choenni, M. Lewis, and E. Shutova, “Metaphor Understanding Challenge Dataset for LLMs,” arXiv preprint arXiv:2403.11810, 2024. [Online]. Available: https://arxiv.org/abs/2403.11810

[7] Viet-Mistral, “Vistral-7B-Chat,” Hugging Face model card. [Online].

Available: https://huggingface.co/Viet-Mistral/Vistral-7B-Chat (accessed Dec. 27, 2025).

[8] VILM, “vinallama-7b-chat,” Hugging Face model card. [Online].

Available: https://huggingface.co/vilm/vinallama-7b-chat (accessed Dec. 27, 2025).

[9] SeaLLMs, “SeaLLMs-v3-7B-Chat,” Hugging Face model card. [Online].

Available: https://huggingface.co/SeaLLMs/SeaLLMs-v3-7B-Chat (accessed Dec. 27, 2025).

[10] Meta, “Meta-Llama-3.1-8B-Instruct,” Hugging Face model card. [Online].

Available: https://huggingface.co/meta-llama/Meta-Llama-3.1-8B-Instruct (accessed Dec. 27, 2025).

[11] Qwen Team, “Qwen2.5-7B-Instruct,” Hugging Face model card. [Online].

Available: https://huggingface.co/Qwen/Qwen2.5-7B-Instruct (accessed Dec. 27, 2025).

[12] Meta, “Llama-2-7b-chat-hf,” Hugging Face model card. [Online].

Available: https://huggingface.co/meta-llama/Llama-2-7b-chat-hf (accessed Dec. 27, 2025).

[13] Cohere Labs, “aya-expanse-8b,” Hugging Face model card. [Online].

Available: https://huggingface.co/CohereLabs/aya-expanse-8b (accessed Dec. 27, 2025).

[14] Q. Nguyen, H. Pham, and D. Dao, “VinaLLaMA: LLaMA-based Vietnamese Foundation Model,” arXiv:2312.11011, 2023. Available: https://arxiv.org/abs/2312.11011

[15] W. Zhang et al., “SeaLLMs 3: Open Foundation and Chat Multilingual Large Language Models for Southeast Asian Languages,” arXiv:2407.19672, 2024. Available: https://arxiv.org/abs/2407.19672

[16] J. Dang et al., “Aya Expanse: Combining Research Breakthroughs for a New Multilingual Frontier,” arXiv:2412.04261, 2024. Available: https://arxiv.org/abs/2412.04261

[17] A. Q. Jiang et al., “Mistral 7B,” arXiv:2310.06825, 2023. Available: https://arxiv.org/abs/2310.06825

[18] E. J. Hu et al., “LoRA: Low-Rank Adaptation of Large Language Models,” arXiv:2106.09685, 2021. Available: https://arxiv.org/abs/2106.09685

[19] L. Ouyang et al., “Training Language Models to Follow Instructions with Human Feedback,” arXiv:2203.02155, 2022. Available: https://arxiv.org/abs/2203.02155

[20] T. Gao, X. Yao, and D. Chen, “SimCSE: Simple Contrastive Learning of Sentence Embeddings,” arXiv:2104.08821, 2021. Available: https://arxiv.org/abs/2104.08821

[21] D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained Language Models for Vietnamese,” in *Findings of EMNLP 2020*, 2020.

[22] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” in *Text Summarization Branches Out*, 2004, pp. 74–81.

[23] M. Popović, “chrF: Character n-gram F-score for Automatic MT Evaluation,” in *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT)*, 2015, pp. 392–395.

[24] J. Cohen, “A Coefficient of Agreement for Nominal Scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.

[25] J. Cohen, “Weighted Kappa: Nominal Scale Agreement with Provision for Scaled Disagreement or Partial Credit,” *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.

[26] M. Birke and A. Sarkar, “A clustering approach for nearly unsupervised recognition of nonliteral language,” in Proceedings of the 11th Conference of the

European Chapter of the Association for Computational Linguistics (EACL), Trento, Italy, 2006, pp. 329–336.

[27] G. Birke and A. Sarkar, “Detecting metaphorical uses of words,” in Proceedings of the 4th Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), Boston, MA, USA, 2006, pp. 105–112.

[28] T. B. Tsvetkov, E. Mukomel, and A. Gershman, “Cross-lingual metaphor detection using common semantic features,” in Proceedings of the 1st Workshop on Metaphor in NLP, Atlanta, GA, USA, 2013, pp. 45–51.

[29] A. Segura-Bedmar, P. Martínez, and M. Herrero-Zazo, “The CoMeta corpus: A corpus annotated with conceptual metaphors,” Language Resources and Evaluation, vol. 55, no. 1, pp. 1–28, 2021.

(CoMeta Corpus – Spanish)

[30] R. Chakrabarty, A. Gupta, and P. Bhattacharyya, “Metaphor detection in natural language inference,” in Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP), Punta Cana, Dominican Republic, 2021, pp. 2449–2461.

[31] Y. Li, J. Wang, and L. Zhang, “A Chinese metaphor corpus and its applications,” in Proceedings of the International Conference on Language Resources and Evaluation (LREC), Miyazaki, Japan, 2018, pp. 286–292.

(Chinese Metaphor Corpus – CMC)

[32] Y. Zhang, Z. Li, and J. Li, “CM3D: A multimodal metaphor dataset for Chinese,” in Proceedings of the 30th ACM International Conference on Multimedia (ACM MM), Lisboa, Portugal, 2022, pp. 1271–1280.

[33] S. Ma, Y. Liang, and Y. Liu, “MultiMM: Multimodal metaphor understanding across cultures,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023, pp. 19234–19243.

[34] R. Chakrabarty, D. Poria, and E. Cambria, “Multimodal metaphor detection using cross-modal representations,” in Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP), Punta Cana, Dominican Republic, 2021, pp. 911–921.

[35] S. Shrestha, A. Joshi, and P. Bhattacharyya, “A Nepali metaphor corpus for low-resource language processing,” in Proceedings of the 13th Language Resources and Evaluation Conference (LREC), Marseille, France, 2022, pp. 3756–3763.